creative commons
COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

언론정보학석사 학위논문

자동화된 팩트체크 과정에서 딥러닝을 이용한 주장(claim) 판별 기법 연구

2022 년 2 월

서울대학교 대학원

언론정보학과 석사과정

박 성 민

자동화된 팩트체크 과정에서 딥러닝을 이용한 주장(claim) 판별 기법 연구

지도 교수 이 준 환

이 논문을 언론정보학석사 학위논문으로 제출함
2021 년 12 월

서울대학교 대학원
언론정보학과 석사과정
박 성 민

박성민의 석사 학위논문을 인준함
2021 년 12 월

위 원 장 한 규 섭 (인)

부위원장 권 가 진 (인)

위 원 이 준 환 (인)

초 록

본 연구는 팩트체크 과정 중, 검증할 대상이 되는 주장을 판별하는 과정을 자동화해보고자 하였다. 이를 위해 팩트체크 검증대상 분류용 데이터셋을 직접 제작하였으며, 이를 기반으로 해당 데이터셋을 딥러닝 언어모델에 학습시켜 실질적으로 검증대상을 판별할 수 있는 분류 모델을 제작한 후 평가하였다.

본 연구에서 제작한 팩트체크 검증대상 분류용 데이터셋은 총 118,119개의 문장으로 이루어져 있으며 과거 한국 정치인의 발화 데이터(홈페이지, SNS, 국회회의록 등을 포함)를 기반으로 제작되었다. 각 문장은 팩트체크 대상이 되는 주장을 판별하기 위한 두 가지 기준인 '검증가능성'과 '검증중요성' 두 개의 이진 라벨을 지니고 있다. 사실적 정보에 대한 주장(factual claim)을 검증가능성이 참인 문장으로 분류하였으며, 이 중 실제 팩트체크의 대상이 되는 내용의 주장을 검증중요성이 참인 문장으로 보았다.

해당 데이터셋과 텍스트 분류 기법을 활용하여, 한국어 팩트체크에서 검증대상이 되는 주장을 판별할 수 있는 분류 모델을 제작하였다. 해당 분류 모델은 한국어 코퍼스를 사전학습한 딥러닝 언어모델인 KoBERT를 전이학습하는 방식으로 제작되었다. 검증가능성과 검증중요성 두 가지 라벨에 대해 각각 이진 분류 모델을 제작하였으며, 그 성능을 정확도, 정밀도, 재현율, F1-점수를 통해 평가하였다. 검증가능성 기준 분류 모델은 모든 지표에서 높은 성능을 보이는 모델을 제작할 수 있었으며 검증중요성 기준 분류 모델 또한 상당한 성능을 지니는 모델을 제작할 수 있었으나 정밀도 부분에서 약간의 한계를 보였다.

본 연구는 한국어 팩트체크 주장 판별을 위한 유의미한 크기의 데이터셋을 최초로 구축하였다. 해당 데이터셋은 이후 팩트체크 자동화 모델뿐만 아니라 한국어 자연어 처리를 위한 데이터셋으로도 활용될 수 있다. 또한, 직접 제작한 분류 모델이 상당히 높은 정확도로 작동하는 것을

확인하였다. 이는 추후 팩트체크 자동화 과정에서 해당 기법이 검증할 대상을 분류해내는 데 실질적으로 활용될 수 있음을 의미한다.

주요어 : 팩트체크, 팩트체크 자동화, 딥러닝, 자연어 처리, 데이터셋
학 번 : 2017-20996

목 차

제 1 장 서 론 1

제 2 장 이론적 배경 8

제 1 절 팩트체크 현황과 과정 8

제 2 절 팩트체크 검증대상 선정 기준 15

제 3 절 알고리즘을 이용한 팩트체크 검증대상 분류 22

제 1 항 자연어 처리와 딥러닝 언어모델 23

제 2 항 알고리즘을 이용한 검증대상 분류 25

제 3 장 연구방법 29

제 1 절 데이터셋 제작 29

제 1 항 데이터셋 29

제 2 항 데이터 분류 기준 30

제 3 항 데이터 라벨링 33

제 2 절 모델 제작 및 평가 36

제 4 장 팩트체크 검증대상 분류용 데이터셋 39

제 5 장 연구결과 43

제 1 절 데이터셋 분할 43

제 2 절 모델 학습 44

제 1 항 검증가능성 모델 44

제 2 항 검증중요성 모델 46

제 3 절 모델 평가 및 예측 결과 48

제 1 항 검증가능성 모델 48

제 2 항 검증중요성 모델 53

제 6 장 논의 및 결론 58
제 1 절 연구내용 요약 58
제 2 절 논의 60

참고문헌 63

표 목차

표 1 CLEF-2021 트위터 데이터셋 제작을 위한 세부 질문 ····· 21

표 2 검증가능성 예/아니오 예시 ····· 31

표 3 검증중요성 예/아니오 예시 ····· 33

표 4 검증가능성 라벨 분포 ····· 39

표 5 검증중요성 라벨 분포 ····· 39

표 6 검증가능성 및 검증중요성 라벨 분포 ····· 39

표 7 분할된 데이터셋 크기 ····· 43

표 8 학습용 데이터셋의 라벨 구성 ····· 43

표 9 검증용 데이터셋의 라벨 구성 ····· 44

표 10 평가용 데이터셋의 라벨 구성 ····· 44

표 11 주기에 따른 검증가능성 모델 학습 결과 ····· 45

표 12 주기에 따른 검증중요성 모델 학습 결과 ····· 47

표 13 검증가능성 모델 예측 결과 오차 행렬 ····· 48

표 14 검증가능성 모델 예측 결과 ····· 49

표 15 검증가능성 모델 예측이 잘 이루어진 예시 ····· 50

표 16 검증가능성 모델 예측이 잘 이루어지지 않은 예시 ····· 52

표 17 검증중요성 모델 예측 결과 오차 행렬 ····· 53

표 18 검증중요성 모델 예측 결과 ····· 53

표 19 검증중요성 모델 예측이 잘 이루어진 예시 ····· 55

표 20 검증중요성 모델 예측이 잘 이루어지지 않은 예시 ····· 56

그림 목차

그림 1 클레임버스터의 팩트체크 문장 분류 자동화 26

그림 2 썰록 데이터 제공 화면 30

그림 3 연구참여자에게 주어진 데이터셋 형태 34

그림 4 제작한 모델 형태 37

그림 5 발화 연도 별 데이터 수 40

그림 6 출처 별 데이터 수 41

그림 7 출처에 정당이 명시된 경우, 정당에 따른 데이터 수 41

그림 8 문장의 길이에 따른 데이터 분포 42

그림 9 주기에 따른 검증가능성 모델 학습 결과 46

그림 10 주기에 따른 검증중요성 모델 학습 결과 47

제 1 장 서 론

디지털 시대에 유통되는 정보의 양이 많아지고 정보의 확산 속도가 빨라지면서, 전통적인 언론의 정보 생산 및 전달 방식은 더 이상 정확성과 사실성을 보장할 수 없다는 의견이 커졌다(Pavlik, 2000). 전통적인 언론의 주된 보도 방식은 객관주의 보도 방식으로서, 화자가 말한 내용을 해석하지 않고 정확하게 전달하는 데 초점을 맞추고 있다(Schudson, 2001; Schudson & Anderson, 2009). 하지만 현재의 미디어 환경에서는 누구나 정보의 생산자가 될 수 있고 그 정보의 전달 속도가 빠르기 때문에, 정치인의 거짓 발화나 선동의 목적을 지닌 가짜 뉴스, 검증되지 않은 거짓 정보가 빠르게 확산되는 일이 많아졌다. 이로 인해 정보의 정확한 전달에 그치지 않고 정보의 사실성을 판단하는 팩트체크 과정의 중요성이 강조되고 있고, 팩트체크를 전문으로 하는 기관에 대한 수요도 커지고 있다. 팩트체크는 '화자가 말한 내용을 정확히 전달하는 것을 넘어, 증거를 기반으로 해당 내용이 사실인지를 규명하는 과정'이라고 할 수 있다(Graves & Amazeen, 2019; Graves & Glaisyer, 2012). 듀크 리포터스 랩(Duke Reporters' Lab)[1]에 따르면, 2020년 10월 기준 전세계 84개국에서 304개의 기관이 팩트체크를 시행하고 있으며 이는 2016년에 보고된 145개에서 2배 이상 늘어났다. 특히 한국에서는 2016년 기준 3개의 기관에서 팩트체크를 진행했다면, 2020년에는 SNU FactCheck, SBS 사실은, 오마이뉴스 오마이팩트, JTBC 팩트체크 등 11개의 기관이 팩트체크를 진행하고 있다.

현재 팩트체크 기관에서는 사람이 직접 사실성을 검증할 대상을 선정하고 사실성 판단 근거가 되는 정보를 찾고 이를 토대로 사실성을 평가한 후, 해당 판단을 근거와 함께 편집해 이용자에게 제공하는 과정을 공통으로 거친다(정은령, 2019; 최순욱 & 윤석민, 2017; Graves, 2017). 하지만 이 모든 과정을 사람이 직접 하고 있기 때문에 허위 정보에

[1] https://reporterslab.org/category/fact-checking/#article-2781

발빠르게 대처하는 데 어려움이 있다. 먼저, 정보가 빠르게 퍼지는 데에 비해 팩트체크를 하는 데 많은 시간이 든다. 정치인의 발화는 소셜 미디어 등을 통해 빠른 속도로 전파되지만, 이 발화의 사실성을 평가하기 위해서는 공식 문서, 과거 뉴스 등의 자료를 검토하고 전문가의 의견을 받아 이를 종합하여 글이나 영상의 형태로 재전파를 해야 한다. 즉, 유권자들은 정치인이 거짓된 정보를 말한 시점에서 상당한 시간이 흐른 후에 해당 정보에 대한 전문가의 판단을 찾아볼 수 있기 때문에 사람들은 필요한 정보를 원하는 때에 접하지 못하게 된다. 또한, 팩트체크가 많은 노력을 요하기에 사람이 검증할 수 있는 정보의 양이 제한적이다. 정보의 사실성을 검증하기 위해서 해당 정보와 관련된 여러 개의 자료를 찾아야 할 뿐만 아니라, 찾은 자료를 그대로 전달하기보다는 이를 토대로 정보의 사실성을 판단하고, 그 판단 근거가 되는 내용을 정보의 이용자들이 납득할 수 있게 설명하여야 한다. 따라서 팩트체크에 대한 수요와 중요성은 높은 데에 비해, 현재의 팩트체크 방식은 많은 양의 정보에 실시간으로 대응하기 어려워 제한적이고 비효율적으로 이루어지고 있다.

보다 효율적이고 효과적인 팩트체크를 위해 짧은 시간에 많은 내용을 전문성 있게 판별하는 시스템의 필요성이 대두되고 있다. 크게 두 가지의 시도가 있는데, 그 중 첫 번째는 크라우드소싱(Crowdsourcing) 방식이며, 두 번째는 알고리즘을 통한 검증 방식이다. 크라우드소싱 방식은 소수의 전문가가 정보를 검증하는 데 드는 시간을 줄이기 위해, 다수의 비전문가들이 참여해 함께 정보를 검증하는 방식이다. 크라우드소싱을 활용한 방식은 수많은 비전문가가 참여하기 때문에 많은 양의 데이터를 단시간에 처리하기에 용이하나, 팩트체크의 품질이 떨어질 수 있다. 실제로 온라인 커뮤니티에서 진행되고 있는 팩트체크를 살펴보면, 팩트체크의 근거로 사용한 내용의 출처를 아예 밝히지 않거나, 밝히더라도 일반 사용자들이 작성한 정보나 대안언론 등 원출처가 아닌 정보를 사용하는 경우가 많다(Hassan et al., 2019).

알고리즘을 이용해 팩트체크 과정의 일부 또는 전체를 자동화하고자

하려는 시도들 또한 등장하고 있다. 알고리즘을 통한 팩트체크 방식은 자연어 처리(NLP;Natural Language Processing)와 딥러닝(Deep Learning)의 발달로 최근 크게 발전했다. 자연어 처리 기법은 알고리즘을 통한 팩트체크에서 핵심이 되는 인공지능 기법으로서, 기존에 컴퓨터가 이해할 수 없었던 인간의 언어를 컴퓨터가 인식하고 처리할 수 있게 만드는 것이다. 자연어 처리의 발달로 인해 컴퓨터는 문장의 내용을 인식하거나, 문장을 만들어내는 등 인간의 언어를 기반으로 하는 작업들을 처리할 수 있게 되었다.

이에 더해, 최근 기계 학습(Machine Learning) 분야 중에서도 딥러닝의 발달로 자연어 처리 성능이 더 향상되었다. 딥러닝은 기계학습의 한 방식이다. 기계학습은 다량의 데이터를 기계가 학습하게 한 뒤, 학습한 내역을 바탕으로 결정을 내리는 알고리즘이다. 전통적인 기계학습 모델을 사용하기 위해서는 데이터의 특성(feature)을 사람이 정의한 후, 이런 특징을 입력 데이터로 이용해야 원하는 결과를 출력하는 모델을 만들 수 있었다. 반면 딥러닝은 인공 신경망(artificial neural network)을 이용해, 사람이 데이터의 특성을 직접 정의하지 않고서도 대량의 데이터 그 자체와 알고리즘을 통해 데이터의 특성을 자동적으로 추출하며, 이 특성을 입력 데이터로 사용하여 모델을 학습시킬 수 있다. 사람이 데이터의 특성을 정의하는 과정을 생략하고 학습을 진행하기 때문에 보다 데이터에 적합한 특성을 스스로 찾아낸다고 볼 수 있으며, 이에 따라 주어진 데이터에서 더 좋은 성능을 지니는 모델을 생성할 수 있다. 하지만 이를 위해서는 대량의 학습데이터가 필요하며, 이 학습데이터를 처리하기 위한 복잡한 알고리즘을 실행시킬 수 있는 좋은 성능의 컴퓨터를 필요로 한다. 컴퓨터 장비, 특히 GPU(Graphics Processing Unit)와 딥러닝 알고리즘의 발달로 비교적 적은 데이터로도 좋은 성능을 낼 수 있는 모델 학습 방법이 연구되고 있는 중이며 팩트체크 시스템에도 이런 인공지능 모델을 적용해보고자 하는 시도가 증가하고 있다(Hidey & Diab, 2018; Ma et al., 2019).

하지만, 아직까지 자연어 처리 기술과 알고리즘은 텍스트의 복잡한

의미를 완전히 파악하는 수준까지는 도달하지 못했다. 이 때문에, 현재 연구되고 있는 알고리즘을 통한 팩트체크는 현재 전문 기관에서 진행하고 있는 팩트체크(fact check)보다는,사실 입증(fact verification) 위주로 진행되고 있다(Thorne et al., 2018b). 전문 기관에서 진행하고 있는 저널리즘에 기반한 팩트체크는 허위정보(misinformation)의 진위 여부를 파악하는 데 집중하기 때문에, 주장의 맥락, 논리성, 일관성을 함께 고려하여 검증한다. 반면, 사실 입증은 주어진 텍스트에 대한 증거 텍스트를 찾은 후, 자연어 추론을 통해 두 텍스트를 비교해 주어진 내용의 사실성을 검증하는 방식이다[2](Thorne et al., 2018a, 2018b; Thorne & Vlachos, 2018). 하지만 사실 입증 과정은 문장 단위에서의 사실성을 파악하는 것이기 때문에 전체적인 발언에서 맥락, 논리성, 일관성 등을 고려하는 팩트체크 단계 이전 선행되어야 하는, 팩트체크의 가장 기초적이고 중요한 과정이라고 볼 수 있다(Thorne & Vlachos, 2018).

인공지능 모델이 팩트체크 시스템을 자동화하기 위해서는 네 가지 문제를 고려해야 한다(Thorne & Vlachos, 2018; Vlachos & Riedel, 2014). (1)우선, 검증할 대상을 선정해야 하고, (2)실질적으로 알고리즘을 통해 검증할 수 있는 정보값을 추출해야 하며, (3)신뢰할 수 있는 출처에서 해당 내용의 사실성을 검증할 수 있는 증거를 찾아야 하며 (4)마지막으로, 해당 증거를 기반으로 사실성을 추론해야 하는 문제가 있다. 모든 단계에서 자연어를 해석하고 연산하는 과정이 필요하기 때문에, 팩트체크 과정을 자동화하기 위한 위의 각 단계 하나하나가 큰 자연어 처리 과제라고 볼 수 있다. 첫 번째 단계인 검증할 대상 선정은 텍스트 더미에서 문장을 추출해 내는 형태로 텍스트를 분류하는 기법(Text Classification)과 관련이 있다. 두 번째로, 해당 문장에서 정보를 추출해 알고리즘의 입력 값으로 변환하기 위해서는 컴퓨터가 처리하기 쉬운 주어-술어-목적어 트리플 구조로 변환하거나 (Ciampaglia et al., 2015), 문장을 직접 처리하여 그 의미를 벡터화하여 처리해야 한다(Hassan et al., 2015b). 다음으로, 입력을

[2] https://www.poynter.org/ifcn/

토대로 증거를 찾는 과정은 정보 검색(Information Retrieval) 과제와 깊은 연관이 있으며 해당 문장과 관련된 메타데이터나 지식 그래프, 텍스트로 된 문서 또는 기존 검증된 클레임에서 증거를 추출하고자 하는 시도가 있다(Ciampaglia et al., 2015; Thorne & Vlachos, 2017; Vlachos & Riedel, 2015; Wang, 2017). 마지막으로 사실성을 검증한 결과를 도출할 때에도 참/거짓의 이진으로 출력할 것인지, 참/대체로 참/대체로 거짓/거짓 등의 다중 스케일로 된 형태로 출력할 것인지 기준을 정하고, 그에 맞춰 데이터를 학습시킬 필요가 있다. 해당 과정은 두 문장 사이의 관계를 학습해 수반(entailment), 모순(contradiction), 중립(neutral) 관계로 예측하는 텍스트 함의 인식 (Recognizing Textual Entailment) 또는 자연어 추론(Natural Language Inference) 과제와 관련이 있다.

팩트체크 자동화 연구에서 위 4가지 문제를 모두 고려하는 경우도 있지만, 크게 두 가지 연구로 나뉘어진다. 첫 번째는 다량의 데이터에서 검증할 주장(claim)을 찾아내는 연구이고, 두 번째는 찾아낸 주장의 사실성을 검증하는 연구이다. 원본 데이터에서 검증할 주장을 분류하는 시스템부터 시작한 연구가 있는가 하면(Hassan, Arslan et al., 2017), 검증할 주장이 이미 주어진 상태로 해당 주장의 사실성을 검증하기 위해 정보값을 추출, 증거 선정 및 사실성을 판단하는 연구가 존재한다(Thorne et al., 2018a; Thorne et al., 2018b).

본 연구에서는 팩트체크의 첫 번째 단계인 검증할 대상 선정을 다루고자 한다. 검증할 대상을 선정하기 위해서는 각 주장이 검증 대상인지 여부를 판별해내는 과정을 필요로 한다. 검증 대상 선정 과정을 자동화하는 것을 통해 짧은 시간 안에 많은 데이터를 검토할 수 있다. 이는 데이터의 생산량과 유통량이 많아지고, 확산 속도 또한 빨라진 현재, 검토해야할 데이터 수를 확연히 줄여줄 수 있다. 이는 현재 전문 기관이 진행하고 있는 팩트체크 과정에서 시간과 비용을 단축하는 데 큰 도움이 될 것이다.

팩트체크 대상이 되는 주장을 알고리즘이 판별하기 위해서 텍스트

분류 기법을 사용할 수 있다. 텍스트 분류 기법은 텍스트를 분석해 해당 텍스트가 어떤 범주에 속하는지 추론하는 작업을 일컬으며 메일 분류, 뉴스 카테고리 분류, 감성 분석 등을 처리하는 데 사용된다. 팩트체크의 대상이 되는 주장을 선정하는 작업 역시 다량의 텍스트가 주어졌을 때, 해당 주장이 팩트체크가 필요한 확률을 추론하여 이를 기반으로 팩트체크 필요성을 수치 또는 범주화된 형태로 나타내는 과제라고 볼 수 있다. 앞서 언급했듯이 알고리즘이 발달하면서, 기존에는 모델을 만들기 위해 직접 분류 규칙을 만들거나 특성을 정의해야 했지만, 점차 많은 데이터를 모델에 넣어 알고리즘이 숨겨진 패턴을 파악하게 하는 딥러닝 기술에 대한 논의가 많아지고 있다. 특히, 딥러닝을 활용한 언어모델은 다량의 언어 코퍼스를 학습한 거대한 모델을 기반으로, 비교적 소량의 데이터를 학습시켜 원하는 과제에 맞게 전이학습을 시킬 수 있다는 점에서, 적은 데이터와 시간으로 좋은 성능을 낼 수 있는 기법으로 떠오르고 있다. 특히 BERT는 문맥을 학습시킨 모델로 다양한 자연어 처리 분야에서 좋은 성과를 내고 있다.

팩트체크의 대상이 되는 주장을 판별하는 과정을 기계학습을 통해서 자동화하려는 시도들이 진행되고 있다. 대표적으로, ClaimBuster[3]는 미국 대선 토론을 기반으로 검증할 대상 선정을 할 수 있는 SVM 모델을 제작하였다(Hassan, Arslan et al., 2017; Hassan, Nayak et al., 2017). 클레임버스터는 이 모델을 토대로 진행되고 있는 대선 토론 내용에서 팩트체크가 필요한 주장을 보다 빠르고 효과적으로 제공하고 있다. 또한, CLEF2019-CheckThat!Lab[4]은 2018년부터 검증할 주장 선정(Check Worthiness) 과 증거 수집 및 사실성 판단(Evidence and Factuality)에 대한 경진대회를 시행하고 있다(Atanasova et al., 2018, 2019; Nakov et al., 2021). 대회에서는 영어와 아랍어 데이터가 제공되었다. 대회 초기에는 전통적인 머신러닝 방식이 대세를 이루었지만 인공신경망을 활용한 딥러닝 방식이 증가하였고, 이후 딥러닝 언어모델을 이용한 방식도 등장하였고 딥러닝 언어모델을 기반으로 한 팀들이 더 좋은 결과를 내는

[3] https://idir.uta.edu/claimbuster/
[4] https://sites.google.com/view/clef2019-checkthat/home

것을 확인할 수 있다.

정리하자면, 딥러닝 알고리즘은 데이터를 스스로 기반으로 규칙을 찾아 결과를 추론할 수 있으며, 대량의 언어 코퍼스를 이미 학습한 딥러닝 언어모델은 자연어 처리 분야에서 큰 두각을 나타내고 있다. 영어와 아랍어 팩트체크 대상 선정 과정에서도 이런 딥러닝 언어 모델을 사용해보고자 하는 연구가 진행되고 있음을 확인할 수 있었다. 자연어 연구의 특성상, 어떤 언어를 사용하는지 또한 모델의 중요한 구성 요소 중 하나인데, 국내에서 해당 단계의 자동화를 다룬 연구가 부족하다.

본 연구는 딥러닝 언어모델을 이용해 한국어 팩트체크 주장 판별 과정의 자동화 가능성을 탐색적으로 살펴볼 것이다. 이에 따라 본 연구의 세부 과제는 크게 두 가지로 나뉜다. 첫 번째는 딥러닝 언어모델에 학습시킬 한국어 팩트체크 주장 판별을 위한 데이터셋을 제작하는 것이다. 두 번째는 해당 데이터로 딥러닝 언어모델을 학습시켜 해당 모델이 실질적으로 검증할 주장을 판별해낼 수 있는지, 가능하다면 어느 정도 수준으로 판별이 가능한지 확인해보는 것이다.

팩트체크 주장 판별 기법의 자동화는 사람이 모든 텍스트를 검토하지 않고도 어떤 문장을 더 주의 깊게 검토해야 하는지 알려줄 수 있다. 또한, 실시간으로 쏟아지는 정보에 대해서도 사람보다 빠른 속도로 대응해 어떤 정보에 대한 판단이 필요한지 알려줄 수 있는 방안이 될 것이다.

제 2 장 이론적 배경

제 1 절 팩트체크 현황과 과정

디지털 시대에 유통되는 정보의 양 증가와 빠른 정보 확산 속도로 인해 전통적인 미디어의 정보 생산 및 전달 방식이 정확성과 사실성을 보장할 수 없다는 의견이 커졌다(Pavlik, 2000). 전통적인 언론의 보도 방식은 객관주의 보도 방식이었다. 객관주의 보도 방식은 정치인 등 화자가 말한 내용을 해석하지 않고 정확하게 전달하고자 하였다(Schudson, 2001; Schudson & Anderson, 2009). 하지만 이는 뉴스가 사실에 입각해 제작된다는 믿음을 기반으로 형성된 방식으로, 뉴스 이용자들은 언론에 사실성을 검증하는 역할을 맡겼다고 할 수 있다. 하지만, 디지털 시대에는 정치인의 거짓 발화, 선동의 목적을 지닌 가짜 뉴스의 범람, 누구나 정보의 생산자가 되어 검증되지 않은 정보를 확산시킬 수 있게 되었다. 한편, 기존 미디어가 정치적인 발언 감시 및 검증자 역할을 제대로 수행하지 못하게 되면서 정보 뿐만 아니라 이를 검증하는 언론의 진실성마저 의심받게 되었다(정은령, 2017, 2019).

기존 미디어는 뉴스와 기관의 신뢰성을 회복하기 위해 정보를 있는 그대로 전달하기 보다는 사실성을 판단해 전달하는 팩트체크 형태의 뉴스를 제작하기 시작했다. 1992년 미국 대통령 선거에서 처음 등장한 팩트체크는 화자가 말한 내용을 정확히 전달하는 것을 넘어 증거를 기반으로 해당 내용이 사실인가를 규명하고자 한다(Graves & Amazeen, 2019; Graves & Glaisyer, 2012). 즉, 언론사와 공공기관, 학자 등의 전문 검증자가 정치인의 발화, 뉴스 등의 사실 여부를 검증하고, 검증한 절차와 내용 그리고 결과를 공개해 팩트체크 정보를 통해 이용자들이 판단을 할 수 있게 돕는 것이 그 목표이다.

팩트체크 뉴스가 이용자들에게 미치는 영향은 아직도 분분하지만

(Amazeen, 2015), 팩트체크의 등장으로 인해 정치인이 부정확한 정보를 덜 말하게 한다는 연구 결과가 있다(Amazeen, 2020; Nyhan & Reifler, 2015). 즉 팩트체크는 허위 정보가 사람들에게 미치는 영향력을 조절하거나, 허위 정보다 덜 생산되도록 정치적 담론을 형성할 수 있다는 것이다. 게다가, 팩트체크 형식의 뉴스가 기존의 객관주의 보도 형태보다 거짓 정보를 수정하는 데 더 효과적이며, 이용자들이 팩트체크 미디어에 대한 선호도가 높다는 점이 더 많은 팩트체크 기관들이 등장하는 계기가 되었다(Amazeen, 2020; Amazeen et al., 2018; Pingree et al., 2014).

대표적인 미국의 팩트체크 기관으로는 팩트체크닷오알지(Factcheck.org) [5], 폴리티팩트(Politifact.com) [6], 워싱턴 포스트의 팩트체커(Fact Checker) [7]를 꼽을 수 있으며, 한국에서는 JTBC의 팩트체크 [8], SNU팩트체크 [9] 등의 팩트체크 전문 기관이 존재한다. 팩트체크닷오알지는 펜실베니아 대학의 공공정책연구소가 설립하였으며, 폴리티팩트는 신문사에서 출발하였으나 현재는 비영리기관에 속해 있다. 반면 워싱턴포스트의 팩트체커나 한국의 JTBC 팩트체크는 미디어 산하 팩트체크 기관이라고 볼 수 있다. SNU팩트체크는 대학과 언론사들이 협업하여 팩트체크를 진행하고 있다.

각 기관이 팩트체크를 진행하는 과정을 전반적으로 살펴보면 다음과 같다. 폴리티팩트의 경우, 편집 회의를 통해 팩트체크 대상이 되는 주장을 선정하고 검증 작업을 시작, 2차례의 검증 과정을 거친 후, 최종 회의를 통해 Truth-O-Meter(진실-대부분 진실-절반의 사실-대부분 허위-허위-새빨간 거짓말)형태의 6단계 팩트체크 검증 결과를 제시한다. 팩트체커의 경우, 정치인의 발언에 포함된 사실들의 팩트 여부를 검증하되 이슈의 내용과 발언에 생략된 문맥과 상황을 분석한 내용을 칼럼 형태로

[5] https://www.factcheck.org/
[6] https://www.politifact.com/
[7] https://www.washingtonpost.com/news/fact-checker/
[8] http://news.jtbc.joins.com/factcheck/
[9] https://factcheck.snu.ac.kr/

제시하고 있다. 이들은 기자의 개인적 역량에 의존하기 때문에 유권자에게 중요하다고 생각되는 소수의 검증 가능한 사실들에 대해서만 검증을 진행하고 있다(마동훈 외, 2013). SNU팩트체크의 경우, 제휴언론사들의 기자들이 검증 대상을 선정하여 해당 대상을 검증할 수 있는 정보와 평가 결과를 제시하면 기관에서 그 내용을 사후적으로 체크하는 형태로 팩트체크 결과를 제시한다(최순욱 & 윤석민, 2017). 해당 기관은 하나의 진술에 대해서 여러 기자들이 검증한 내용을 종합적으로 보여주고 있다. 실제 기자들의 팩트체크 과정이 어떻게 객관성을 가지게 되는지 분석한 연구에서는, 팩트체크 과정을 다섯 단계로 제시한다 (Graves, 2017). (1)먼저 정치인 등의 발언 중 검증가능하고 뉴스 가치가 있는 사실에 관한 내용을 선정하고, (2)해당 발언의 화자와 연락을 시도한 뒤, (3)해당 발언이 등장한 배경을 역추적하고, (4)여기서 얻은 정보를 전문가나 공식 문서를 이용해 검증한 후, (5)마지막으로 발언의 선정 이유, 근거의 출처 및 선정 이유 및 최종 평가에 대한 내용을 정리해서 게시한다.

이들의 공통점은 팩트체크 과정이 전부 전문가들의 손에 의해 이루어진다는 점이다. 대학이나, 기관에 소속된 전문가, 언론사에 속한 기자들이 직접 사실성을 검증할 주장(Claim)을 선정한 후, 해당 주장의 사실성을 판단할 수 있는 정보를 찾아, 이를 토대로 사실성을 판단한 뒤 전체 내용을 정리해 게시하고 있다. 하지만 전문가에 의해 이 모든 과정이 이루어지고 있기 때문에 팩트체크 뉴스의 질은 높을 수 있으나 허위 정보에 발빠르게 대응하는 데 어려움이 있다.

먼저, 정보가 빠르게 퍼지는 데에 비해 팩트체크를 하는 데 많은 시간이 든다. 유명인, 정치인 등의 주요 발언 창구가 기존 언론뿐만 아니라 소셜 미디어, 팟캐스트 등으로 확장되어 검토해야 할 텍스트의 양이 증가하였으며, 해당 발언이 전파되는 속도 또한 빨라졌다. 하지만, 상대적으로 소수인 전문가들은 먼저 수많은 텍스트 중 어떤 주장을 검토할지 정해야 한다. 그 다음으로는 해당 주장의 사실성을 평가하기 위해서 공식 문서, 과거 뉴스 등의 자료를 검토하고 필요할 경우 자료에 관련된

전문가의 의견을 받아 이를 종합하여 글이나 영상의 형태로 제작한 후, 재전파를 해야 한다. 이렇게 생성된 팩트체크 뉴스는, 전문가가 판단하기에 팩트체크가 필요한 주장이며, 그 근거 또한 공식 자료를 사용하였고, 전문가에 의해 편집되었기에 상당히 신뢰도가 높을 수 있다. 하지만, 이 자료를 접하게 될 유권자들은 거짓된 정보를 접한 시점에서 상당한 시간이 흐른 후에만 해당 정보에 대한 전문가의 판단을 찾아볼 수 있기 때문에 이런 방식은 사람들에게 필요한 정보를 원하는 때에 제공하기 적합하지 않을 수 있다.

또한, 팩트체크 과정은 많은 노력을 요하기에 사람이 검증할 수 있는 정보의 양이 제한적이다. 앞서 말했듯 다양한 채널에서 텍스트를 검토해야 할 뿐만 아니라, 텍스트의 양은 상당한 데에 비해 한 정보의 사실성을 검증하기 위해서 해당 정보와 관련된 여러 개의 자료를 찾아야 하며, 찾은 자료를 그대로 전달하기보다는 이를 토대로 정보의 사실성은 판단하고, 그 판단 근거가 되는 내용을 정보의 이용자들이 납득할 수 있게 설명하여야 한다(정은령, 2019; Graves, 2017). 따라서 팩트체크에 대한 수요와 중요성은 높은 데에 비해, 현재의 전문가 위주의 팩트체크 방식은 많은 양의 정보에 실시간으로 대응하기 어려워 제한적이고 비효율적으로 이루어지고 있다.

이에 대응해, 크라우드소싱을 팩트체크에 적용해보고자 하는 시도들이 생겨났다. 크라우드소싱 방식의 팩트체크는 보다 많은 사람들이 참여하기 때문에 더욱 다양한 주제와 더 많은 양의 데이터를 확인하기에 용이하다. 하지만, 전문가가 아니기에 이런 방식은 복잡한 내용을 팩트체크하기에는 적합한 방식이 아닐 수 있다. 실제로 영국의 팩트체크 기관인 풀팩트(fullfact.org)[10]에서 2015년 선거를 모니터링 하기 위해 120명의 자원자를 통해 팩트체크할 문장을 선정해보았으나, 빠른 속도로 다양한 주제나 영역에 대한 내용을 다룰 수는 있었지만 복잡한 내용을 다루기는 어려웠다고 말한다. 대표적인 크라우드소싱 팩트체크 프로젝트인

[10] https://fullfact.org/

트루스쿼드(TruthSquad)는 팩트체크닷오알지에서 2010년 진행한 파일럿 프로젝트로 프로젝트 참여자들에게 언론인들의 도움을 받아 팩트체크를 진행해보게 하였다. 하지만, 참여자들이 판단한 결과가 예상보다 유용하지 않았으며, 사실성에 대한 증거로 사용된 내용의 삼분의 이 이상은 언론인들이 기존에 수집한 내용이었다고 한다[11]. 게다가, 팩트체크EU(FactcheckEU)의 설립자이자 국제 팩트체크 네트워크의 전 관리자이자 현재 구글 뉴스와 정보 신뢰도 팀의 리더인 Alexios Mantzarlis는 팩트체크의 여러 과정에 크라우드소싱을 적용했을 때 발생할 수 있는 문제에 대해 언급했다[12][13]. 먼저 팩트체크 대상이 되는 문장을 선정하는 과정에서 정치적으로 치우치거나 그 출처가 치우칠 수 있으며, 무보수의 크라우드소싱에 참여하는 사람들은 가계수익이 높을 가능성이 높아 문장 선정에 치우침이 있을 수 있다고 얘기한다. 또한, 크라우드소싱을 통해 더 적은 인력으로 팩트체크가 가능하리라 예측했지만 이를 편집해서 내보내는 과정과 품질 유지를 위해 전문가의 인력이 지속적으로 필요했다고 말한다. 여기에 더해, 온라인 커뮤니티 사이트 레딧의 “politicalfactchecking” 서브레딧을 분석한 결과, 사람들이 팩트체크의 근거를 아예 제시하지 않았거나 제시하더라도 위키피디아, 레딧 등 원 출처가 아닌 정보를 사용하는 비율이 높아 팩트체크에 대한 품질을 전문가에 비해 보장하기 어렵다고 할 수 있다(Hassan et al., 2019).

또한, 컴퓨터를 이용해 팩트체크를 자동화하려는 시도들도 등장하고 있다. 컴퓨터를 저널리즘 분야에 활용해 전문가가 이를 활용하면 보다 효과적인 탐사보도를 할 수 있다는 청사진이 제시된 바 있다(Cohen et al., 2011). 컴퓨터를 통해 팩트체크의 각 과정(검증 대상 선정, 증거 검출 및

[11] http://mediashift.org/2010/11/crowdsourced-fact-checking-what-we-learned-from-truthsquad320/
[12] https://www.niemanlab.org/2018/06/can-crowdsourcing-scale-fact-checking-up-up-up-probably-not-and-heres-why/
[13] https://fullfact.org/blog/2018/may/crowdsourced-factchecking/

판단)을 자동화한다면, 현재의 노동집약적이고 시간이 오래 걸리는 전문가 팩트체크를 개선할 수 있을 것이다. 또한 크라우드소싱과 달리 정보의 출처에 제한을 두고 모델을 학습시키는 방법을 통해 품질을 개선할 수 있을 것이다. 저널리즘 팩트체크와 현재 팩트체크의 과정은 인공지능의 주요 분야 중 하나인 자연어 처리 기술과 깊은 연관이 있다(Thorne & Vlachos, 2018; Vlachos & Riedel, 2014). 팩트체크 자동화 시스템을 만드는 데 중요한 4가지 문제와 그에 해당하는 기술을 정리하면 다음과 같다.

(1)팩트체크 검증 대상 여부 판별: 텍스트 분류(Text Classification)

(2)해당 문장에서 어떤 정보를 알고리즘의 입력값으로 넣을지 선정하기: 정보 검색 쿼리 생성

(3)증거를 어떤 방식으로 찾고 해당 증거의 신뢰도를 어떻게 검증할 것인지 정하기: 정보 검색(Information Retrieval)

(4)검증한 결과를 어떤 방식으로 출력할 것인지 정하기: 텍스트 함의 인식(Recognizing Textual Entailment), 자연어 추론(Natural Language Inference)

전체 텍스트에서 팩트체크 대상을 선정하기 위해서는 텍스트 단위가 되는 각 문장이 팩트체크 검증 대상 여부인지 판별하는 것이 필요하다. 즉, 주어진 문장들을 검증 대상 여부 기준으로 분류함으로써 팩트체크 대상을 선정할 수 있다. 팩트체크 대상이 되는 문장에서 증거를 확보하기 위해서는 해당 문장에서 어떤 정보값을 사용하는지 정해야 할 필요가 있다. 정보 검색 쿼리를 주어-술어-목적어 형태의 트리플이나 문장 전체를 벡터화하여 알고리즘의 입력값으로 설정한다(Ciampaglia et al., 2015). 그 이후, 증거를 찾기 위해 메타데이터나 지식 그래프, 문서, 이미 팩트체크된 문장 데이터셋 등을 활용한 연구가 진행 중이다(Thorne & Vlachos, 2017; Vlachos & Riedel, 2015; Wang, 2017). 마지막으로 해당 증거와 검증할 문장을 비교하여 두 문장 사이의 관계를 토대로 참/거짓을 설명한다. 여기서 보듯 자동화 시스템의 각 부분이 하나의 큰

연구 주제라고 할 수 있다.

하지만 실제 팩트체크 기관에서 행하고 있는 정치인의 발화를 팩트체크하는 과정은 현재 컴퓨터가 자동으로 처리하고 있는 수준보다 더 많은 판단과 맥락을 필요로 하기 때문에, 현재 사실 검증 자동화는 해당 문장의 맥락, 일관성, 논리성을 고려한 팩트체크라기보다는 단순한 수준의 문장 관계 파악을 통한 사실 입증(fact verification)위주로 진행되고 있다(Graves, 2018; Thorne et al., 2018a, 2018b).

먼저, 검증할 대상을 선정하는 과정에서 자동화를 활용하고자 한 시도가 존재한다. 클레임버스터 (Claimbuster)[14]는 과거 토론 데이터를 이용해 토론의 각 문장이 팩트체크가 필요한 확률을 기계학습을 통해 계산하여 다량의 토론 데이터에서 팩트체크가 필요할 가능성이 높은 문장을 1차적으로 표시해줌으로써 전체 데이터를 보지 않고도 기자들에게 우선적으로 체크해야 할 대상을 알려준다(Hassan, Adair et al., 2015; Hassan, Arslan et al., 2017; Hassan, Li et al., 2015; Hassan, Nayak et al., 2017; Hassan et al., 2016). 풀팩트(fullfact.org)가 진행한 프로젝트에서는 문장을 검증가능성으로 분류하고, 이를 학습시킨 모델을 통해 전문가들이 검증 대상이 되는 문장을 선정하는 과정을 돕는 벤치마크를 만들었다(Konstantinovskiy et al., 2018).

검증해야 할 대상에 관한 정보를 찾고 사실성을 추론하기 위해서 만들어지고 있는 데이터나 모델은 크게 두 가지 경로를 따른다. 위키백과 등 원본 데이터가 정해진 상황에서 문장의 참 거짓을 판단하고 그를 뒷받침할 증거를 찾거나(Mihaylova et al., 2019; Thorne et al., 2018a, 2018b), 웹 기반 검색과 웹사이트에 대한 신뢰도 등을 토대로 증거를 추출해 해당 증거를 기반으로 판단을 하는 경우이다(Atanasova et al., 2019; Karadzhov et al., 2017).

즉, 기존 팩트체크 과정을 (1)검증 대상 선정 (2)증거 검출 및 판단의 과정으로 재분류해 컴퓨터를 통해 이를 자동화하기 위한 시도들이 조금씩 생겨나고 있으나 아직까지는 실제 기관보다 낮은 수준에서 이루어지고

[14] https://idir.uta.edu/claimbuster/

있으며, 완전한 자동화를 위한 초석이 되는 연구가 진행 중이라고 할 수 있다. 본 논문에서는 팩트체크라는 큰 과정의 첫 단계인 팩트체크가 필요한 주장을 선정하는 과정을 집중적으로 분석하여, 자동화의 가능성을 탐색적으로 살펴보고자 한다.

제 2 절 검증대상 선정 기준

2016년 설립된 국제 팩트체크 네트워크(International Fact-Checking Network: IFCN)[15]는 팩트체크 준칙을 제정해 팩트체크 기관들이 최소한으로 지켜야 할 것이 무엇인지 제시하고 있다. 해당 준칙은 (1) 비정파성과 공정성 (Non-partisanship and Fairness), (2) 취재원 투명성 (Transparency of Sources), (3) 재정과 기관 투명성 (Transparency of Funding & Organization), (4) 검증과정의 투명성 (Transparency of Methodology), (5) 공개적이고 정직한 수정(Open and Honest Corrections)의 5개 항목으로 이루어져 있다. 해당 팩트체크 준칙은 팩트체크의 투명성과 불편부당성을 중심으로 작성되어 있으며(이나연, 2018), 특히 투명성은 독자의 신뢰도와 직결되기 때문에 중요하다. 어떤 대상을 왜 선정했고, 누가 어떤 과정과 자료를 통해 어떤 결론을 내렸는지 투명하게 공개함으로써 해당 내용의 이용자들이 해당 검증에 대한 신뢰도를 얻을 수 있다는 것이다. 팩트체크 원칙 중, 4) 검증과정의 투명성은 팩트체커들이 검증대상을 선정, 조사, 기사작성 및 게시하는 내용이 투명하게 공개되어 있는지를 의미한다. 그 중, 검증대상을 선정함에 있어 검증가능성과 중요성을 통해 왜 해당 문장을 검증대상으로 선정했는지 설명할 수 있어야 한다고 제시한다.

[15] https://www.ifcncodeofprinciples.poynter.org/know-more/the-commitments-of-the-code-of-principles

먼저 팩트체크 기관들은 사실성을 검증하는 것이 목적이기에 사실성을 판단할 수 없는 의견을 검증하지는 않으며, 사실에 근거한 주장(factual claim)을 검증 대상으로 삼는다. 사실이 관찰에 의해 증명될 수 있거나 과거로 기록된 경험적 사실, 특정 제도나 사회적 장치로 형성된 사회적 사실을 말한다면, 주장의 사실성을 판단하기 위해서는 그 근거로 경험적 사실이나 사회적 사실을 제시할 수 있어야 한다[16]. 주장이 거짓이라 함은 해당 주장이 경험적 사실이나 사회적 사실과 모순이 되기 때문이라 할 수 있다. 반면, 의견은 사실을 토대로 타당성을 검증할 수 없는 대상이기에 기관들은 우선적으로 사실에 근거한 주장이 아닌 의견을 1차적으로 제외한다.

폴리티팩트(Politifact)는 검증할 대상을 선정하기 위해 자연스러운 질문이 유발되는가, 정치적으로 중요성을 지니는가, 실제 검증이 가능한가의 세 가지 기준을 사용한다고 말한다. 팩트체크닷오알지(Factcheck.org)는 정치인의 여러 토크쇼, 텔레비전 광고, 연설, 선거 캠페인 등에서 전문가들이 진위가 의심되는 문장을 선정해 해당 내용을 검토하여 거짓인 경우를 위주로 팩트체크를 진행하며 민주당과 공화당의 발언을 골고루 다루고자 한다. 워싱턴 포스트의 팩트체커(Fact Checker)는 해당 기관이 사실을 검증하는 기관이며 의견을 검증하지 않기 때문에 검증가능한 사실을 다루며, 유권자에게 중요한 내용이자 뉴스 가치가 있는 내용을 다루고 있으며, 좌우의 내용을 공정하게 다루고자 노력하고 있다고 이야기한다. SNU팩트체크 또한, 검증대상을 선정할 때 (1) 시민의 공적 생활이나, 시민의 보건, 환경 등에 영향을 미칠 수 있는 중요한 사안 등의 정당한 공적 관심사와 관련이 있음, (2) 실질적 근거로 사실성을 가릴 수 있으며 의견은 검증대상이 될 수 없음, (3) 시민들이 팩트체크 검증대상을 제안의 기준으로 검증대상을 선정하고 있다.

하지만 사실에 근거한 주장을 검증대상으로 삼더라도 진위를 판단하기 어려운 경우가 존재한다. 팩트체크를 비판한 연구(Uscinski & Butler,

[16] http://wp.auburn.edu/rdggenie/home/critical/fact-opinion/

2013)에 의하면, 팩트체크할 수 없는 대상이 세 가지 존재한다고 말한다. 먼저, 인과적인 내용은 개별 정책과 변화에 대한 사실성을 논의할 수는 있지만 변화의 원인으로 정책을 평가하기 어렵다고 말한다. 또, 미래를 예측하는 발언에 대해서도 현재 전문가들이 그 내용을 평가할 수는 있지만 그 평가가 사실성을 가진다고 말하기 어려움을 언급한다. 마지막으로, 정치적 수사를 포함한 내용 또한 사실성을 검증할 수 없는 내용이라고 말한다. 실제로 KBS 팩트체크 팀은 순수한 주장, 수사적 표현, 미래 예측, 인과 관계를 검증 대상으로 포함하지 않고 있다. 해당 기관은 검증 대상 선정에 대한 운영 원칙을 (1)사회적으로 오해와 오인을 불러올 수 있거나 (2)반복 유통될 소지가 다분하거나 (3)대중적인 의문이 제기될 수 있는, 그리고 (4)자유와 평등, 인권 등 민주주의를 공격하는 내용을 검증 대상 선정에 대한 운영 원칙으로 발표했다[17]. 한편, 이런 비판에 대해 전문가의 팩트체크 과정은 사실성을 검증하는 과정을 투명하게 공개하기 때문에 원인이나 정책의 효과를 직접 다루지 않더라도 해석적으로 해당 발언에 대한 정보를 제공해줄 수 있다는 점에서 팩트체크의 의미가 있다는 논의도 존재한다(박아란 외, 2018; 이나연, 2018).

팩트체크 대상 선정에 있어 전문가나 기관의 편향성이 존재한다는 비판도 있다. 국내 방송사들의 팩트체크 전문가들을 인터뷰한 연구(정은령, 2019)에서는 팩트체크 뉴스 제작 시 검증대상을 선정하는 과정에서 기자 개인이나 소속사의 경향성, 그리고 방송이 될 법한, 실시간 주요 이슈를 위주로 선정한다. 이들은 방송사라는 특성상 팩트체크 내용을 공표하는 시간이 제한되어 있기에 관심의 집중도와 실시간성이 중요한 요소로 등장했고, 이전의 팩트체크 기관들과는 달리 좌우의 내용을 공정하게 다루기 보다는 개별 방송사의 방송 흐름을 고려해 검증대상을 선정하고 있다. 기자 개인의 주관뿐만 아니라 편집회의를 통해 목표한 시청자와 회사의 방침 등을 고려하기 때문에 가치판단의 영역이 들어갈 수밖에 없어 정파성이 존재할 수 있음을 언급한다. 즉, 대부분의 팩트체크 기관은

[17] https://news.kbs.co.kr/news/view.do?ncd=4368944

팩트체크할 대상을 선정하는 데 있어 사실에 근거한 주장을 선정하고는 있지만 그 안에서 어떤 내용을 다룰지 선택하는 것은 무엇이 정치적으로 중요한가, 시청자들에게 필요한 정보가 무엇인가, 시청자가 원하는 정보가 무엇인가 등의 기자나 기관의 주관에 의해서 결정되기 때문에 검증대상 선택에서 편향성이 나타날 수 있다는 비판이 있다. 이런 편향성이 언론사와 정치인의 성향에 따라 나타나는 지 확인한 연구(이나연, 2018)에서는 편향성이 존재할 수 있지만, 이견을 동시에 보여줌으로써 이용자의 판단을 도울 수 있다고 말한다.

앞서 언급한 전문 팩트체크 기관과 비교하여, 팩트체크 자동화를 다룬 연구에서는 팩트체크 대상 선정 기준을 어떻게 잡고 있으며, 그에 따라 데이터셋을 어떻게 제작하였는지 살펴보았다. 팩트체크 자동화 과정에 대해 논의한 연구에서는 우선 팩트체크 과정을 “객관적으로 사실성을 평가할 수 있는 주장을 선정해 이를 시기, 화자, 여러 근거 자료 및 해석을 통해 판단하는 과정"이라 정의하였다(Vlachos & Riedel, 2014). 여기서 객관적으로 사실성을 평가할 수 있는 주장이라 함은, 사실에 근거한 주장 중 인과관계, 미래예측 등 알고리즘을 통해 사실성을 평가하기 어려운 주장을 제외한 것을 말한다. 해당 연구는 사실성을 알고리즘으로 평가할 수 있는 주장 중, 중요한 내용을 자동화된 팩트체크로 검증할 대상이라고 정의하였다. 즉, 전문 팩트체크 기관의 기준과 마찬가지로 인과관계 및 미래예측을 평가하는 문장은 제외했다. 하지만 알고리즘은 많은 데이터를 활용해 특정한 조건이나 패턴을 찾는 것은 사람보다 용이하게 할 수 있지만 전반적인 사회적, 정치적 배경을 고려하여 의도를 파악할 수는 없다. 따라서, 팩트체크 자동화 과정에서는 데이터를 통해서만 판단할 수 있는 영역만 자동화 과정으로 포함시키고 사람의 의도가 들어가거나 주관성이 필요한 영역은 자동화 과정에서 제외시킨다.

실제로 팩트체크 자동화를 위한 데이터셋을 어떻게 만들었는지 살펴보면 해당 연구에서 알고리즘으로 평가할 수 있는 문장의 범위를 알 수 있다. 먼저, 전문가가 판단한 기관의 데이터를 가져와 그대로 자동화

데이터로 사용한 경우가 있다. CLEF-2019[18]는 팩트체크 문장 선정과 자동화를 과제로 삼은 경진대회이다. 해당 대회에서 제공한 팩트체크 데이터는 팩트체크닷오알지에서 선정한 데이터를 가져와 그들이 검증한 문장을 검증할 만한 대상으로, 검증하지 않은 대상을 검증할 필요가 없는 대상으로 만든 데이터이다(Nakov et al., 2018). 전문가가 이미 평가한 내용을 검증할 만한 문장으로 삼은 이 방식은 하나의 기관이 평가한 데이터에 대해서만 다뤘기에 선정이 편향적일 가능성이 있으며, 2016년 미국 대선 토론 데이터만을 사용하였기에 일반화하기 힘든 데이터일 가능성이 높다. 2016년 미국 대선 토론을 기반으로 9개의 팩트체크 기관에서 진행한 내용을 데이터셋으로 만들어 검증 대상을 분류한 연구가 존재한다(Patwari et al., 2017). 여러 팩트체크 기관의 관점을 보았기에 편향성의 문제는 줄어들었을 수는 있으나 대선 토론 데이터만을 다뤘기에 일반화하기 힘든 문제는 여전하다. 여기에 더해 기존의 팩트체크 기관이 팩트체크 대상으로 선정한 데이터만을 검증이 필요한 데이터로, 그 외의 문장은 검증이 필요하지 않은 데이터로 처리하는 방식은 또다른 문제를 발생시킨다. 전문가들이 한정된 시간과 인력으로 선정한 문장만이 검증 가능하다고 판별된다는 점에서 선정된 내용들은 중요도가 큰 내용들이며 그 품질이 높다고 할 수는 있다. 하지만, 필요하지 않다고 처리된 데이터 중에서는 사실 팩트체크가 필요한 내용이 존재할 수 있다. 즉, 이런 데이터를 사용한다면 팩트체크가 필요하다고 판단된 내용 중 실제로 팩트체크가 필요한 내용의 비율을 말하는 정밀도(Precision)는 높아도 팩트체크가 필요한 내용 중 실제로 팩트체크가 필요하다고 판단된 비율을 말하는 재현율(Recall)이 떨어지는 결과가 나올 수 있다는 것이 해당 방식의 큰 문제이다. 실제로 CLEF는 이 문제를 인지하여, 2021년 경진대회 용으로 제작한 정치토론 데이터셋에서는 전문가가 다룬 문장에, 연구자들이 추가로 데이터를 검토하였다(Nakov et al., 2021).

[18] https://sites.google.com/view/clef2019-checkthat

직접 검증할 문장을 선정하기 위한 데이터를 만든 시도들 또한 존재한다. 클레임버스터는 전문가 팩트체크의 기준과 유사하게 중요한 사실 기반의 주장을 선별하고자 하였다(Arslan et al., 2020; Hassan, Adair et al., 2015; Hassan, Nayak et al., 2017; Hassan et al., 2016). 이들은 세 개의 라벨로 데이터를 형성했다. (1)NFS(Non-Factual Sentences)는 주관적인 문장, 의견, 믿음, 수사학적 표현 등의 문장들을 포함하며, (2)UFS(Unimportant Factual Sentences)는 사실 기반의 주장으로 팩트체크가 가능하나 대중에게 관심을 끌지 못할 내용들이 포함되었으며, (3)CFS(Checkworthy Factual Sentences)는 사실 기반의 주장이면서 대중이 그 사실성에 관심이 있을 것 같은 문장에 붙은 라벨이다. 이 CFS 라벨에는 데이터를 다루는 문장, 과거의 사건에 대한 문장 등이 포함되었다. 이들은 이 데이터를 만들기 위해 1960년부터 2016년까지 진행된 미국 대선 토론 데이터를 사용하였다. 우선, 발화자의 말 중 후보자 발언을 대상으로 너무 짧은 문장들은 제거하였다. 그 다음, 사람을 교육시켜 분류를 진행하였다. 크라우드소싱 방식과 유사하게 총 23,533개의 문장을 분류하게 하였으며, 품질을 보증하기 위해 분류작업자들에게 인센티브를 주고, 랭킹 시스템을 통해 전반적인 품질을 올리고자 하였다. 또한 우수 작업자들의 내용 위주로 데이터를 구성한 후, 전문가들이 분류된 일부 문장에 대한 라벨을 재검토하는 과정을 거쳤다. 해당 데이터셋은 이전의 방식과 달리 전문가가 아니라 크라우드소싱 방식을 사용하여 훨씬 더 많은 데이터를 검토할 수 있었으며 크라우드소싱이 가져올 수 있는 품질 저하를 고려해 데이터를 제작하였다. 하지만, 결국 '중요성'을 판단한다는 것은 시의성에 의존적인데, 지금의 기준으로 과거의 데이터를 평가하는 방식이 적합한 방식이라는 보장은 없다.

CLEF는 2021년 경진대회에서 트위터 데이터셋을 제작하였다. 트위터에서 코로나-19, 정치 관련 트윗을 모아 전문가에게 해당 트윗을 분류하는 방식으로 데이터를 제작하였다(Nakov et al., 2021). 해당 연구에서는 검증할 대상을 선정하기 위해 한 트윗당 6가지의 질문을 구성했다.

1. 트위터가 검증가능한 사실에 관한 주장(verifiable factual claim)을 지니고 있는가? (1에 “예”라고 대답했으면 나머지 2~6질문에 답을 한다.)
2. 트윗에 존재하는 주장이 거짓으로 보이는가? 3. 트윗에 존재하는 주장이 대중의 흥미를 끌거나 대중에게 영향을 줄 것 같다고 생각하는가? 4. 트윗에 존재하는 주장이 도덕적으로나 실제적으로 국가 등에 얼마나 해로운 존재인가? 5. 기자들이 해당 주장의 확산이나, 주장이 포함하고 있는 정보를 다루고 싶어한다고 생각하는가?
6. 팩트체크 전문가나 기자가 트윗에 존재하는 주장을 검증해야 한다고 생각하는가?

표 1 CLEF-2021 트위터 데이터셋 제작을 위한 세부 질문

1번 질문을 통해 검증가능한 정보가 있는지 확인하는 것이 우선이었다. 1번은 객관적인 정보에 대한 질문으로, 정의나 현재나 과거의 수치정보, 검증가능한 미래 정보, 법률이나 상관관계 등이 검증가능한 내용이라고 보았다. 그리고 검증할 가치가 있는지 확인하는 기준에 주관성이 있음을 인정하고, 세부 질문을 2~5번으로 제시해 검증 대상이 되는 주장의 기준을 보다 구체적으로 다루었다. 마지막 6번 질문과 함께, 검증이 필요한 주장으로 거짓 정보를 포함하며, 대중의 흥미를 이끌어내며, 해로워 보이는 트윗을 대상으로 삼았다. 최종적으로, 1번과 6번 질문에 모두 “예”라고 답을 해야 검증할 대상으로 삼았다. 각 트윗은 2~5명의 사람이 답을 했으며, 불합치한 경우 합의과정을 거쳤다. 해당 연구는 구체적인 세부질문을 세워 주관적이고 편향될 수 있는 검증기준에 어느 정도 합의를 가져오고자 하였다. 해당 데이터셋은 총 5개 국어(아랍어, 불가리아어, 영어, 스페인어, 터키어)의 트윗을 포함하지만, 데이터 수가 총 18,014로 한 언어 당 평균 3,602.8개의 트윗 밖에 존재하지 않는다. 즉, 구체적인 기준을 세운 것은 좋았으나 데이터의 수가 적어 형성된 데이터셋의

대표성을 보장하기 어려울 수 있다.

이에 풀팩트의 프로젝트는 시간에 관계없이 일관성 있는 문장 검출을 위해, '중요성' 부분은 전문가의 주관성에 맡기고 사실성을 검증가능한 문장을 분류하고, 이진분류(검증불가능, 검증가능) 방식과 다중분류(개인경험, 인과관계, 예측, 수량 검증, 법 등) 방식을 이용해 주장을 세부적으로 분류해 전문가의 팩트체크에 도움을 줄 수 있는 방식을 고안하였다(Konstantinovskiy et al., 2018).

추가로, 실제 자동화 팩트체크 과정 중 사실성 검증 과정에서 연구한 데이터셋을 확인해보면 간접적으로 어떤 문장이 팩트체크, 특히 알고리즘 팩트체크의 대상이 되는지 알 수 있다. 사실성 검증 알고리즘을 위한 경진대회에서 제공한 데이터셋 FEVER(Fact Extraction and Verification)에서는 평균 8단어 내외의 합성문장이 아닌 간단한 문장을 검증하는 형태로 진행되고 있었다(Thorne et al., 2018b).

제 3 절 알고리즘을 이용한 팩트체크 검증대상 분류

팩트체크 검증대상이 되는 문장을 선정하는 것은 결국, 검증대상이 되는 문장과 그렇지 않은 문장을 분류해내는 것과 동일하다. 알고리즘을 이용한 검증대상 분류는 각 문장이 팩트체크가 필요한 확률을 추론하여 해당 문장이 어느 범주에 속하는지 판별하는 것이 그 핵심이라고 할 수 있다. 이에 따라, 자연어 처리 분야 중 텍스트 분류 기법을 통해 이를 자동화하고자 하는 시도들이 등장하고 있다. 따라서 텍스트 분류 과정에서 자연어 처리 기법이 어떻게 작동하고 어떤 특성을 지닌 알고리즘이 사용되고 있는지 살펴볼 필요가 있으며, 실제로 검증대상 분류 모델을 만들고자 하는 시도를 확인할 필요가 있다. 검증대상이 되는 문장을 알고리즘을 통해 자동으로 분류해내는 것은 사람이 모든 텍스트를 검토하지 않고도 어떤 문장을 더 주의 깊게 검토해야 하는지 알려줄 수 있다. 또한, 실시간으로 쏟아지는 정보에 대해서도 사람보다 빠른 속도로

대응해 어떤 정보에 대한 판단이 필요한지 알려줄 수 있는 방안이 될 것이다.

1) 자연어 처리와 딥러닝 언어모델

자연어 처리는 인간의 언어를 분석해 의미를 컴퓨터로 처리하는 다양한 기법을 말한다. 인간의 언어는 일반적으로 다루는 수치 데이터와 달리 형태가 정해져 있지 않은 비정형 데이터이기 때문에 그 의미를 파악하기 위해서 자연어 처리 기법을 사용한다. 그 중, 텍스트 분류 기법은 텍스트의 내용을 분석해 해당 텍스트가 어떤 범주에 속하는지 분류하는 기법을 말한다. 텍스트 분류 기법은 메일 분류, 뉴스 카테고리 분류, 감성 분석 등을 처리하는 데 주로 사용된다. 특히 텍스트를 자동으로 분류하기 위해 여러 알고리즘 접근법이 제시되었는데, 규칙 기반(rule-based) 접근법, 머신러닝(data-driven) 접근법, 그리고 이를 혼합해 사용하는 접근법으로 분류할 수 있다. 규칙 기반 접근법은 사전에 정해진 규칙에 따라 텍스트를 분류하는 형태로, 이런 접근법은 사전 지식이 충분히 많아야 모든 사례들에 대해 텍스트를 효과적으로 분류할 수 있다. 이에 비해 머신러닝 접근법은 데이터를 통해 컴퓨터가 자체적으로 규칙을 습득하도록 학습시켜 모델을 생성한 후, 텍스트를 자동으로 분류하는 모든 기법을 말한다. 이런 기법은 규칙을 직접 설정할 필요는 없지만 규칙을 학습하기 위해 많은 양의 데이터를 필요로 한다.

전통적인 머신러닝 모델을 만들기 위해서는 텍스트에서 직접 특성을 추출해낸 다음, 해당 특성을 이용해 분류하는 과정을 거친다. 특성을 사용한 전통적인 방식의 분류 알고리즘에는 Naïve Bayesian, SVM(Support Vector Machine), HMM(Hidden Markov Model), Gradient Boosting Trees, Random Forests 등이 있다. 하지만 이런 머신러닝 기법은 특성을 직접 추출해야 하기 때문에, 해당 특성을 만들고 분석하여 좋은 성능을 낼 수 있도록 작업을 반복해야 한다. 또한, 특성을 해당 영역의 정보에 의존적으로 생성하기에 다른 영역에 확장하기 어려워 새로운 영역에서는 새로운 모델을 만들어야 한다. 또한, 이미 정해진

특성만을 이용해 분류하기 때문에 원본 텍스트에서 데이터가 소실되는 부분이 있어 데이터의 양이 어느 정도 이상을 넘어가도, 특성을 어떻게 설정하느냐에 따라 그 성능이 정해진다(Minaee et al., 2020).

2012년 딥러닝 모델 AlexNet(Krizhevsky et al., 2012)의 등장은 기존의 전통적인 머신러닝 기법보다 이미지 분류 분야에서 단숨에 뛰어난 성적을 거두면서 기존의 자연어 처리, 이미지 처리 등 다양한 분야에 적용되기 시작했다. 딥러닝은 인공 신경망을 기반으로 만들어진 모델로, 데이터를 넣으면 해당 데이터에서 숨겨진 패턴을 찾아, 이를 기반으로 문제를 해결할 수 있다. 여기에 더해 머신러닝과 달리 딥러닝 모델은 한 문제에서 다른 문제로 전이학습이 가능하다는 점에서, 여러 형태의 딥러닝 모델이 개발되어 사용되고 있다. 특히, 텍스트 분류를 포함하는 자연어를 처리하는 분야에서 딥러닝 모델은 여러 구조를 통해 발달해왔다. 자연어 처리에 관련된 대표적인 모델 구조와 그 특성은 다음과 같다. (1)RNN(Recurrent Neural Network) 구조를 통해 연속된 단어의 의미를 분석하는 모델을 만들었고, (2)LSTM(Long Short Term Memory) 구조로 보다 긴 문장의 의미를 분석할 수 있게 되었고, (3)어텐션(attention) 구조로 연속된 단어 뿐만 아니라 한 문장 내에 존재하는 개별 단어 사이의 관계를 기반으로 텍스트를 분석할 수 있게 되었고, (4)트랜스포머(transformer) 구조를 통해 연속된 단어를 병렬적으로 처리할 수 있게 되면서 더 많은 양의 데이터를 효율적으로 학습할 수 있게 되었다. 특히, 트랜스포머의 등장은 거대한 딥러닝 언어모델의 등장으로 이어졌다.

언어모델은 연속하는 단어 시퀀스에 확률을 할당해 그 시퀀스가 얼마나 자연스러운가를 파악하는 모델이라고 할 수 있다. 딥러닝을 통해 만든 언어모델은 해당 확률을 많은 데이터로부터 학습해 모델이 해당 언어에 대한 정보를 지니고 있다고 볼 수 있다. 대표적인 딥러닝 언어모델 중 하나는 2018년 등장한 BERT(Devlin et al., 2018)이다. 구글에서 공개한 BERT는 언어 이해에 대한 내용을 사전학습한 거대한 모델이라고 할 수 있다. 해당 모델은 이미 대용량 데이터를 통해 자연어를 사전학습한

형태로 해당 모델을 이용해 다른 자연어 문제를 해결하는 데 전이학습을 시킬 수 있다. 거대한 딥러닝 모델을 활용한 전이학습은 비교적 적은 데이터와 학습량으로, 빠르고 좋은 성과를 기대할 수 있다. 실제로, 질의응답이나 텍스트 분류, NLI(Natural Language Inference) 등의 다양한 자연어 처리 분야에 BERT 언어모델을 적용하여 좋은 성과를 내고 있다(Garg et al., 2019; Liu et al., 2019; Mihaylova et al., 2019; Minaee et al., 2020; C. Sun et al., 2019). 거기에 더해 BERT는 이전의 다른 딥러닝 언어모델인 ELMo(Peters et al., 2018), OpenAI GPT(Radford et al., 2018)와 다르게 문맥에 의존하여 단어를 학습시켰기 때문에 해당 단어의 전후에 등장하는 내용을 살펴 해당 단어를 분석할 수 있는 모델이라고 할 수 있다.

BERT는 BERT-multilingual 즉, 다국어 언어모델을 함께 제공하고 있지만, 해당 언어모델이 학습한 한국어의 양이 부족하고, 한국어는 영어와 다른 구조를 지니고 있음에도 영어와 같은 형식으로 학습되었기 때문에 그 성능에 한계가 있다. 이에 SKTBrain에서 기존의 BERT 모델 구조를 한국어 위키와 한국어 뉴스로 이루어진 대량의 한국어 코퍼스를 이용해 학습시켜 KoBERT 언어모델을 제시하였다[19].

2) 알고리즘을 이용한 검증대상 분류

지금까지 텍스트 분류 기법을 적용해 검증대상 분류 자동화를 위한 다양한 방법이 제시되었다. 대표적으로, ClaimBuster [20] 는 전통적인 머신러닝 기법을 활용하여 미국 대선 토론을 기반으로 검증할 대상을 분류할 수 있는 SVM 모델을 제작하였다(Hassan, Li et al., 2015; Hassan, Nayak et al., 2017; Hassan et al., 2016). 클레임버스터는 그림 1에서 보듯 해당 모델을 토대로 진행되고 있는 대선 토론 내용에서 각 문장이 검증이 필요한 확률을 계산한 후 그 값에 따라 하이라이트해서

[19] https://github.com/SKTBrain/KoBERT
[20] https://idir.uta.edu/claimbuster/

보여줌으로써, 사람들이 토론 내용을 볼 때 어떤 문장이 중요하고 검증이 필요한지 알려준다. 즉, 사람들이 모든 토론 내용을 살펴보지 않고도 진하게 하이라이트된 내용을 위주로 토론 내용을 검토할 수 있다. 해당 시스템을 사용하면 전문가들도 보다 빠르고 효과적으로 팩트체크할 문장을 선정할 수 있다. 또한, 실시간으로 쏟아지는 정보에 대해서도 사람보다 빠른 속도로 대응해 어떤 정보에 대한 판단이 필요한지 알려줄 수도 있다.

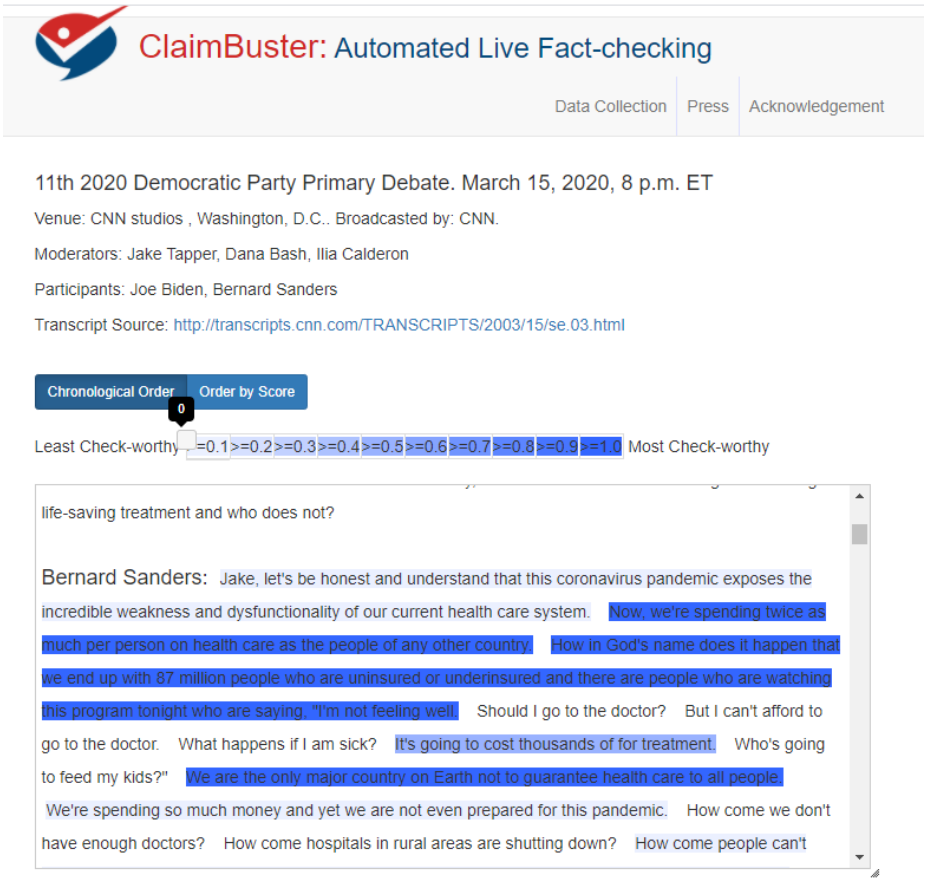


그림 1 클레임버스터의 팩트체크 문장 분류 자동화

CLEF2019-CheckThat!Lab[21] 은 2018년부터 팩트체크 검증대상 분류(Check Worthiness)와 증거 수집 및 사실성 판단(Evidence and Factuality)에 대한 경진대회를 시행하고 있다(Nakov et al., 2018). 해당 데이터는 앞서 말했듯이 팩트체크 기관의 판단을 기반으로 생성되어 있다.

[21] https://sites.google.com/view/clef2019-checkthat/home

여기에 참가한 팀 중 하나는 검증의 중요성을 측정하기 위해 클레임버스터의 대선 토론 내용을 학습시킨 후, 해당 맥락을 기반으로 검증이 필요한지를 측정하여 베이스라인보다 훨씬 더 정확한 성능을 낼 수 있었다(Hansen et al., 2019).

앞서 언급한 풀팩트 프로젝트는 알고리즘을 통한 팩트체크 자동화 과정에서는 해당 문장의 중요성을 판단할 수 없기에 검증의 중요성을 배제하였다. 해당 프로젝트는 알고리즘을 통해 어떤 문장의 사실성 검증이 가능한 문장을 다양한 형태로 분류한 데이터를 만들었다 (Konstantinovskiy et al., 2018). 해당 연구는 문장을 수량에 관한 주장, 개인적 경험에 관한 주장, 법률에 관한 주장, 미래예측에 관련된 주장, 인과관계를 포함한 주장, 주장이 아닌 문장, 기타 주장으로 나누어 해당 문장이 어디 속해 있는지 분류한 후, 수량에 관한 주장만을 검증 가능한 문장으로 두었다. 그 후, 사전학습된 언어 정보, 클레임버스터, 풀팩트의 분류 결과 등을 각각 특성으로 삼아 로지스틱 회귀를 통해 분류하는 모델을 제시하였다.

CLEF2021에서는 트위터 데이터와 정치 토론 데이터 2개의 데이터셋에 대해 검증 가능한 문장을 분류하는 과제가 존재하였다. 해당 대회 제출자를 확인해 보면, 불과 2년 사이에 대다수의 팀들이 BERT 기반의 다양한 딥러닝 언어모델을 기반으로 대회 결과를 제출한 내역을 확인할 수 있다(Nakov et al., 2021). 하지만, 앞서 언급했던 것처럼 트위터 데이터는 평균적인 수가 적어 데이터의 대표성을 보장하기 어렵다. 정치 토론 데이터의 경우 세 팀이 대회에 제출을 하였으며 전부 BERT 기반의 모델을 사용한 것을 확인할 수 있었다.

여기서 보듯 자연어 처리와 텍스트 분류 기법이 발달했지만, 이는 비교적 최근의 일로, 팩트체크가 필요한 문장을 분류하는 데 딥러닝 언어모델을 적용해보는 연구가 진행 중이다. 실질적으로 해당 모델을 팩트체크 과정에 쓰려면 아직 많은 논의가 필요하다. 또한, 자연어 처리의 특성 상 어떤 언어가 처리 대상이 되는지도 중요한 요소이다. 딥러닝

언어모델을 이용해 한국어로 텍스트 분류를 하는 시도들은 존재하지만 (전영호, 2019; 황상흠 & 김도현, 2020), 한국어로 된 팩트체크 검증 대상 분류 시도는 그 이전에 찾아보기 힘들다.

본 연구에서는 딥러닝 언어모델을 한국어 알고리즘 팩트체크 과정에 직접 적용시켜보고자 한다. 앞서 살펴본 검증대상 선정 기준을 토대로 제작한 데이터를 딥러닝 언어모델에 학습시켰을 때, 해당 분류모델이 실질적으로 검증대상이 되는 문장을 분류할 수 있는지 직접 데이터부터 모델까지 만들어 확인해보고자 한다, 즉, 알고리즘이 검증대상이 되는 주장(claim)을 판별해낼 수 있는지 확인해보는 것이 해당 연구의 가장 큰 목표이다. 제작된 분류 모델을 이용해 분류 정확도를 확인, 한국어 팩트체크 검증대상 분류 모델의 성능을 확인해보고자 한다.

연구문제 1. 딥러닝 언어모델을 이용해 한국어 팩트체크에서 검증대상이 되는 주장(claim)을 판별해낼 수 있는가.

연구문제 2. 딥러닝 언어모델을 이용해 한국어 팩트체크에서 검증대상이 되는 주장(claim)을 분류했을 때 해당 모델의 분류 정확도 수준은 어떠한가.

제 3 장 연구방법

본 연구는 알고리즘 팩트체크의 두 가지 주요 과제인 (1)사실성을 검증할 대상 선정 (2)해당 문장의 사실성 평가 중 사실성을 검증할 대상 선정과정에 집중한다. 팩트체크할 문장 선정 과정을 자동화해보기 위해 팩트체크할 문장 선정 과정을 텍스트 분류 과제로 보았으며, 지도학습 방법을 이용하여 모델을 제작하였다. 지도학습 방법을 이용하기 위해서는 정답이 있는 데이터셋을 필요로 한다. 본 연구에서는 과거 정치인의 발화 데이터를 기반으로 라벨링된 데이터셋을 직접 제작하였다. 정치인의 발화를 문장 단위로 끊었으며, 각 문장에 (1)검증가능성, (2)검증중요성에 대해 각각 예/아니오로 구성된 이진 라벨을 부여하였다. 데이터셋이 완성된 다음, 각 라벨에 대해 이진 분류를 할 수 있도록 KoBERT를 미세조정하여 2개의 모델을 제작하였다. 이후, 각 모델의 성능을 검토하는 과정을 거쳤다.

제 1 절 데이터셋 제작

1) 데이터셋

한국 정치인의 과거 발화 데이터는 중앙일보에서 제공하는 썰록[22]을 활용하여 수집하였다.

썰록은 청와대 홈페이지, 정당의 보도자료, 논평, 성명 및 브리핑, 정치인의 SNS(페이스북, 트위터) 그리고 국회회의록에 포함된 발언들에 대해 발화일, 출처, 발화자 그리고 발화내용을 제공하고 있다. 1997년부터 2020년 3월까지의 데이터를 보유 중이며, 문장 단위로 끊어진 형태로 데이터를 제공하기 때문에 본 연구에 적합한 형태라고 할 수 있다.

[22] http://ssullog.joins.com/



그림 2 썰록 데이터 제공 화면

2) 데이터 분류 기준

본 연구에서 팩트체크의 대상이 되는 문장을 분류하기 위해 사용하는 기준은 두 가지 (1)검증가능성 그리고 (2)검증중요성이다.

검증가능성은 문장이 사실적 정보를 포함하고 있는지에 대한 기준으로, 해당 조건은 팩트체크 대상이 되기 위한 필요조건이라고 볼 수 있다. 각 문장의 사실성을 검증할 수 있는 경우 “예”로, 그렇지 않은 경우 “아니오”로 분류된다. 사실성을 검증할 수 있는 문장들은 실제 일어난 일 등 객관적 사실이나 그런 사실에 관한 주장, 그리고 누가 어떤 말을 했다는 발화사실 등을 포함한다. 반면, 믿음이나 감정표현, 다짐, 계획, 추측, 공약 등은 사실성을 검증할 수 없는 문장에 속한다. 구체적 사실을 포함하지 않은 수사적 표현 또한 사실성을 검증하기 어려운 문장에 속한다.

검증가능성

예	– 벌써 분단된 지 70년이다. – 김기현 前 울산시장 관련 비위 혐의에 대해 청와대의 하명수사가 있었다는 언론보도는 사실 무근입니다 – 어제 문재인 대통령이 '소득하위 70%, 가구당 100만원 지원' 내용의 지원책을 발표했습니다 – 오늘 김근식 송파병 후보 선거사무소 방문에는 김종인 총괄선대위원장을 비롯해 김웅 송파갑 후보, 배현진 송파을 후보, 박춘희 前 송파구청장, 최명길 前 의원 등이 함께 했다
아니오	– 청와대의 거짓 브리핑의 속내, 그 음흉한 의도는 무엇이었는가 – 다양한 인공지능 분야에서 성공을 거두고 있는 기업인과 개발자 여러분, 매우 든든하고 고맙습니다. – 외교부장의 방한을 환영합니다 – 추미애 후보 지명을 계기로 법무·검찰 개혁이 흔들림 없이 앞으로 나아가길 바라며, 더불어민주당도 우리 사회의 정의를 바로세우기 위해 최선의 노력을 다하겠다.

표 2 검증가능성 예/아니오 예시

검증중요성은 문장이 팩트체크할 만한 가치가 있는지에 대한 라벨이다. 해당 라벨은 검증 가능성이 있는 문장들 중, 실제 팩트체크의 대상이 될 문장들을 분류하기 위함이다. 즉, 검증가능성이 "예"인 항목들 중에서 중요한 사실적 정보를 포함해 검증할만한 가치가 있는 문장은 "예"로, 그렇지 않은 문장은 "아니오"로 분류된다. 한편, 검증가능성이 "아니오"로 분류된 문장의 검증중요성은 모두 "아니오"로 분류된다. 팩트체크의 대상이 되는 문장은 일반 대중이 해당 문장이 포함하는 사실적 정보의 참거짓 여부에 관심을 가질만한 문장이다. 해당 기준은 분류하는 사람의 주관적인 판단을 요구하기 때문에 더 일관성 있는 판단을 위하여 하위기준을 구성하였다. 기존의 검증가치(check-worthiness) 데이터셋

연구(Hassan, Arslan et al., 2017; Nakov et al., 2021)를 참고하여, 하위기준 3가지를 구성하였다. 하위기준은 아래 세 가지로 구성되어 있다.

(1) 사회적으로 중요한 내용을 포함하고 있는가
(2) 해당 내용이 가져올 수 있는 부정적인 영향이 큰 내용인가
(3) 언론인들이 팩트체크할 법한 내용인가

해당 3가지 내용 중 하나라도 부합한다면 검증할만한 가치가 있는 문장으로 분류될 수 있다고 보았다. 검증중요성이 “예”로 분류되는 대표적인 사실적 정보는 정책의 효과, 사건이나 정책에 대한 평가, 그리고 법률위반여부이다. 반면, 단순한 설명이나 일상적인 내용, 사소한 행적은 사회적으로 중요한 내용을 포함하고 있다고 보기 어려우므로 검증중요성이 “아니오”로 분류되는 대표적인 문장들이다.

검증중요성

예	– 김기현 前 울산시장 관련 비위 혐의에 대해 청와대의 하명수사가 있었다는 언론보도는 사실 무근입니다 – 어제 문재인 대통령이 '소득하위 70%, 가구당 100만원 지원' 내용의 지원책을 발표했습니다
아니오	**(팩트체크의 대상이 되지 않는 사실적 정보)** – 벌써 분단된 지 70년이다. – 오늘 김근식 송파병 후보 선거사무소 방문에는 김종인 총괄선대위원장을 비롯해 김웅 송파갑 후보, 배현진 송파을 후보, 박춘희 前 송파구청장, 최명길 前 의원 등이 함께 했다 **(검증가능성이 "아니오"인 경우)** – 청와대의 거짓 브리핑의 속내, 그 음흉한 의도는 무엇이었는가 – 다양한 인공지능 분야에서 성공을 거두고 있는 기업인과 개발자 여러분, 매우 든든하고 고맙습니다. – 외교부장의 방한을 환영합니다 – 추미애 후보 지명을 계기로 법무·검찰 개혁이 흔들림 없이 앞으로 나아가길 바라며, 더불어민주당도 우리 사회의 정의를 바로세우기 위해 최선의 노력을 다하겠다.

표 3 검증중요성 예/아니오 예시

3) 데이터 라벨링

지도학습 방법을 사용하여 모델을 학습시키기 위해서는, 일정한 기준에 따라 라벨링이 완료된 문장 데이터가 필요하다. 기존에 한국어로 된 팩트체크 대상 선정에 대한 데이터가 따로 존재하지 않았기 때문에, 썰록에서 수집한 문장을 위의 데이터 분류 기준으로 라벨링할 연구참여자를 모집하였다.

데이터셋 제작에 참여한 연구참여자는 총 15명으로, 정치인의 발화를

이해하고 해당 내용의 사실성과 맥락을 파악할 수 있을 정도로 한국어가 능숙한, 모국어가 한국어인 사람을 모집하였다. 각자 작업 가능한 컴퓨터(데스크탑 또는 노트북)를 소유하고 있으며 성별은 무관하나 만 18세 이상의 성인을 대상으로 모집하였다. 온라인 대학생 커뮤니티인 스누라이프[23], 에브리타임[24] 그리고 사용자 조사연구 참여자 사이트 모집[25]에 모집 공고를 게시하였으며, 눈덩이 표집 방법을 통해서도 모집하였다.

모집 완료 후, 데이터셋 제작은 2021년 11월 10일부터 25일까지 총 16일간 진행되었으며 코로나 19 상황을 감안하여 모든 과정은 비대면으로 이루어졌다. 10일, 11일 양일간 약 30분가량의 연구 설명 및 데이터셋 제작 방식에 대한 교육이 이루어졌으며 모든 참가자는 둘 중 하나의 세션에 참석하였다. 사전 교육에서는 연구에 대한 설명 및 동의서 작성, 팩트체크 뉴스에 대한 소개, 데이터셋의 형태와 라벨링 기준 및 라벨 분류 예시 그리고 일정에 대한 안내가 있었다.

아래는 주어진 데이터셋의 형태이다.

date	src	speaker	Document	label1: 검증가능성	label2: 검증중요성
2020-03-31	페이스북	나경원	만나는 주민들마다 간절한 눈빛으로 "저도 그 돈 받을 수 있을까요?"라고 묻습니다	예/아니오	
2020-03-31	페이스북	나경원	어제 문재인 대통령이 '소득하위 70%, 가구당 100만원 지원' 내용의 지원책을 발표했습니다	dropdown	
2020-03-31	페이스북	나경원	동네는 그야말로 뒤집어졌습니다		
2020-03-31	페이스북	나경원	하루하루가 힘든 국민들에게는 가뭄에 단비 같은 소식이겠지요.		
2020-03-31	페이스북	나경원	기대감에 들뜬 국민 중 누군가는 분명 실망해야 할 수도 있습니다.		
2020-03-31	페이스북	나경원	하지만 정작 누가 얼마나 지원금을 받을 수 있는지 아직 알 수 없다고 합니다		
2020-03-31	페이스북	나경원	소득 산정 시점도 불투명하고, 재산이나 채무 등을 반영하기 때문에 아직 누가 돈을 받을 수 있는지도 알 수가 없습니다		

그림 3 연구참여자에게 주어진 데이터셋 형태

연구자는 해당 기간 동안 한 명당 최대 13,000개의 문장을 지급받아 라벨링을 진행하였고, 중도에 포기할 경우 라벨링을 진행한 내역에 비례하여 사례비를 지급하였다. 데이터는 공유 구글 스프레드시트를 통해

[23] https://www.snulife.com/
[24] https://everytime.kr/
[25] https://mozip.snu.ac.kr/

제공되었으며, 연구참여자 별로 문서를 따로 생성하여 각 문서는 연구참여자 본인과 연구자에게만 공유되었다. 이를 통해, 연구자는 언제든 연구참여자의 데이터셋 제작 현황을 확인할 수 있었다. 연구참여기간 동안, 연구참여자와 연구자는 1:1 오픈채팅방을 통해 소통하였다. 오픈채팅방과 메일을 통해 라벨링 내역에 대한 질문을 받아 답변을 하였으며, 중간점검, 피드백 제공 및 일정관리가 해당 채널을 통해 지속적으로 이루어졌다.

사전교육이 끝난 후, 각 연구참여자에게 약 1,000건의 문장을 포함한 데이터를 우선 지급하였다. 해당 데이터는 정해진 기한까지 모두 라벨링을 완료하도록 요청하였으며, 각 문장당 2명의 연구참여자가 중복으로 라벨링하여 문장의 라벨값 간의 일치도를 확인하였다. 또한, 연구참여자 사이에 불합치가 일어난 부분을 연구자가 확인한 후, 실수나 잘못 파악하고 있는 점에 대한 피드백을 메일과 1:1 오픈채팅을 통해 제공하였다. 이후 각 연구참여자에게 약 7,000건의 문장과 약 5,000건의 문장으로 이루어진 데이터를 2번에 걸쳐 추가로 제공하여 라벨링을 진행하였다. 두 번째로 주어진 7,000건의 문장까지는 개별 문장이 중복으로 라벨링될 수 있도록 하여, 문장의 라벨값에 대한 일치도를 추가적으로 확인하였다.

처음에 주어진 데이터에 대해서 문장의 검증가능성에 대한 초기일치도는 0.8038로 나왔으며, 검증중요성에 대한 초기일치도는 0.8374로 나왔다. 피드백 이후, 각 연구참여자에게 주어진 7,000개의 데이터에 대해 2차로 측정한 결과 검증가능성에 대한 일치도는 0.8367로, 검증중요성에 대한 일치도는 0.8460으로 상승하였다. 피드백을 통해 보다 일관성 있게 라벨링이 이루어졌음을 확인할 수 있었다. 일치하지 않은 문장은 피드백 과정에서 하나의 라벨로 일치시켜 데이터셋에 포함시켰다.

15명의 연구참여자 중 11명의 연구참여자가 주어진 약 13,000개의 문장에 대한 라벨링을 완료하였으며, 4명의 연구참여자는 기간 내에 주어진 분량을 완수하지 못하였다. 완수하지 못하였더라도 해당 데이터는 연구참여자의 동의를 거쳐 실제 데이터셋에 포함되었다.

제 2 절 분류 모델 제작 및 평가

앞서 만든 데이터셋을 기반으로, 언어모델을 활용한 딥러닝 알고리즘이 해당 문장 분류를 실제로 학습하여, 실질적으로 분류가 가능한지 확인해보고자 모델을 제작하였다. 비정형 데이터를 다루기 위한 자연어 처리 기법 중 하나인 딥러닝 언어모델은 이미 수많은 언어 데이터를 학습한 모델로, 모델 전이학습을 통해 비교적 적은 데이터로도 뛰어난 성능을 내는 것이 그 특징이다. 그 중 BERT는 단어의 맥락에 따라 의미를 다르게 해석할 수 있도록 제작된 모델이기 때문에 동음이의어가 많은 경우에도 효과적으로 활용될 수 있으며 맥락 정보를 읽는데 상대적으로 뛰어난 모델이라고 볼 수 있다.

BERT 모델을 기반으로 한국어를 사전학습한 모델은 BERT-multilingual과 KoBERT가 존재한다. KoBERT는 BERT-multilingual 모델의 한국어 성능 한계를 개선하기 위해 SKTBrain에서 한국어 위키와 뉴스 텍스트 학습하여 만든 모델로 네이버 영화 리뷰 감성 분석 등의 세부 과제에서 BERT-multilingual 모델보다 좋은 성능을 보였다.

본 연구에서는 해당 KoBERT 모델을 활용하여, 새로 만들어진 팩트체크 문장 선정 과정에 전이학습을 시켜본 후, 모델의 성능을 측정해 실질적으로 분류가 가능한지 확인하였다. 한국어 위키와 한국어 뉴스로 이루어진 코퍼스에 학습된 KoBERT 모델을 기반으로 마지막에 이진 분류를 위한 선형 층 하나를 추가하였다. 하나의 문장에 검증가능성과 검증중요성 2개의 라벨을 부여했으므로, 각각의 라벨을 따로 모델로 제작하여 해당 모델이 검증가능성과 검증중요성을 얼마나 잘 분류해내는지 확인하였다. 두 라벨은 모두 “예”와 “아니오”로 이루어진 이진 라벨이었기에, 각 모델은 하나의 문장을 입력받았을 때, 예 또는 아니오로 응답하는 이진 분류 방식으로 작동하도록 제작하였다.

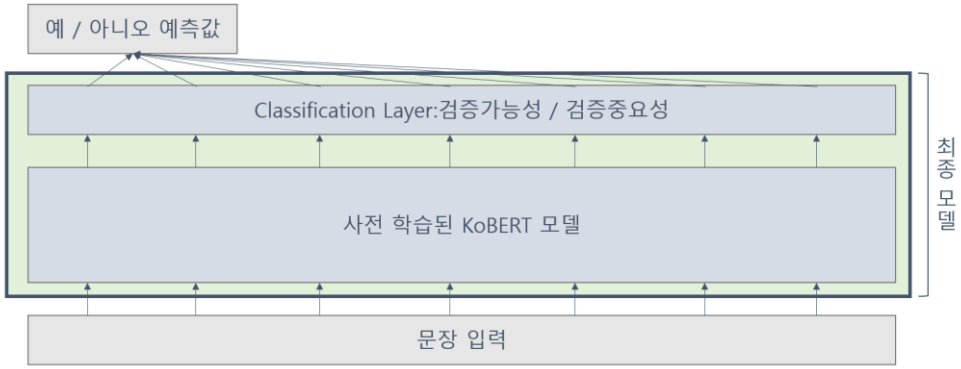


그림 4 제작한 모델 형태

모델의 성능을 검증하기 위해서는 데이터셋 전부를 학습에 활용하는 것이 아니라, 학습용 데이터(train set)와 검증용 데이터(validation set), 그리고 평가용 데이터(test set)로 나눌 필요성이 있다. 학습용 데이터는 모델이 직접적으로 학습하는 데이터이며, 검증용 데이터는 학습 중간 하이퍼파라미터(hyperparameter)에 따른 각자 다른 모델 버전의성능을 확인할 수 있는 데이터로 활용된다. 학습용 데이터를 통해 생성된 모델이 일반적으로 활용될 수 있는 모델인지, 학습용 데이터에만 잘 작동하는 모델인지 검증용 데이터를 통해 확인할 수 있다. 검증용 데이터에서 좋은 성능을 보인 모델을 선택하여 최종적으로 평가용 데이터에 적용시켜 보면, 해당 모델이 새로운 데이터에 대해서 얼마나 좋은 성능을 보이는지 확인할 수 있다.

일반적으로 분류 모델의 성능을 검증하는 지표는 4가지가 있다. 정확도(Accuracy), 정밀도(Precision), 재현율(Recall) 그리고 F1-점수(F1-Score)이다. 정확도는 라벨을 정확하게 예측한 비율로, 전체 데이터에서 참양성(True Positive)와 참음성(True Negative)의 비율이다. 하지만, 단순히 정확도가 높다고 만들어진 모델이 잘 작동한다고 말하기는 어렵다. 데이터가 편향된 경우, 특히 이 문제점이 커진다. 예를 들어, 데이터 값에 참이 많은 경우, 모델이 양성 결과를 내뱉는 것만으로도 모델의 정확도는 높게 나올 수 있다. 따라서, 데이터의 형태에 따라서

추가적인 지표를 검토할 필요가 있다. 정밀도는 모델이 참으로 예측한 데이터 중 모델이 정확히 예측한 데이터의 비율이며, 재현율은 실제로 참인 데이터 중 모델이 정확히 참으로 예측한 데이터의 비율이다. 정밀도가 낮을수록, 거짓양성(False Positive)가 많다는 뜻이며 이는 제1종 오류의 비율이 높다는 뜻이며 재현율이 낮을수록 거짓음성(False Negative)가 많다는 뜻이며 이는 제2종 오류를 많이 범하고 있다는 뜻이다. 정밀도와 재현율은 한쪽을 올릴수록 한쪽이 낮아지는 상충하는 측면이 있기에, 이 둘의 조화평균인 F1-점수를 사용하여 모델의 성능을 측정하기도 한다. 또한 데이터셋의 특성과 모델이 무엇을 예측하는가에 따라 중점적으로 보는 지표가 달라질 수 있다. 본 연구에서는 데이터의 특성을 먼저 확인한 후, 네 가지 지표를 종합적으로 고려하여 모델을 선택하였다.

제 4 장 팩트체크 검증대상 분류용 데이터셋

해당 데이터셋은 팩트체크 검증대상 기준으로 라벨링된 데이터셋이다. 검증대상 기준에는 “검증가능성”과 “검증중요성” 두 가지의 기준이 존재한다. “검증가능성”은 해당 문장이 사실적 정보에 관한 주장(factual claim)을 포함하고 있는지에 대한 라벨이며, “검증중요성”은 검증이 가능한 주장 중 검증가치가 있는지에 대한 라벨이다.

라벨링된 최종 데이터는 118,119개의 문장으로 이루어져 있다. 각 문장에는 검증가능성과 검증중요성 라벨이 각각 “예” 또는 “아니오”의 이진라벨으로 분류되어 있다. 아래 표는 각 라벨에 속하는 문장의 수를 보여준다.

검증가능성	문장 수(비율)
예	35,873(0.3037)
아니오	82,246(0.6963)

표 4 검증가능성 라벨 분포

검증중요성	문장 수(비율)
예	20,489(0.1735)
아니오	97,630(0.8265)

표 5 검증중요성 라벨 분포

검증가능성	검증중요성	문장 수(비율)
예	예	20,489(0.1735)
	아니오	15,384(0.1302)
아니오	아니오	82,246(0.6963)

표 6 검증가능성 및 검증중요성 라벨 분포

전체 데이터의 발화연도에 따른 구성은 아래와 같다. 발화 연도의 범위는 1997년에서 2020년 3월까지이나, 현재에 가까워질수록 데이터양이 증가하는 것을 확인하였다. 이는 SNS의 발달로 인해 정치인의 발화 데이터의 크기가 점차 커졌음을 반영하기도 한다. 하지만, 데이터의 전반적인 주제나 발화자의 구성에 어느 정도 편향이 있음을 시사한다.

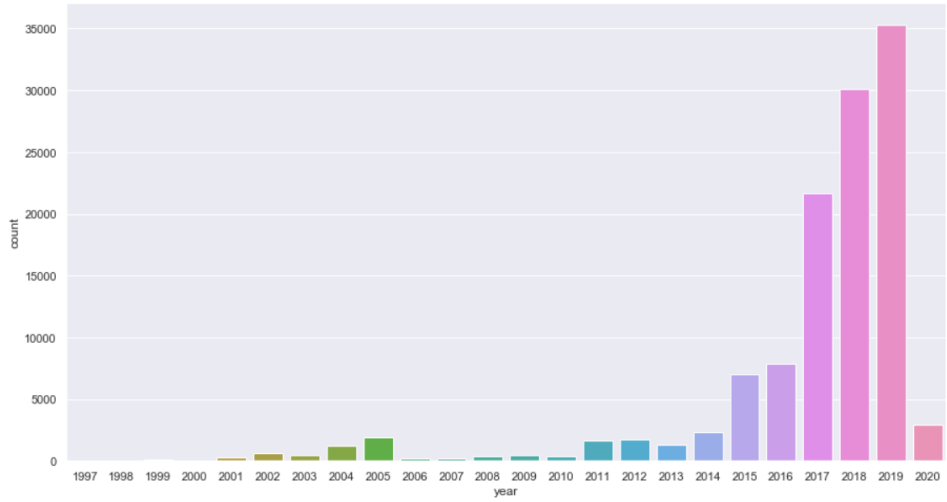


그림 5 발화 연도 별 데이터 수

전체 데이터의 출처에 따른 구성은 아래와 같다. 정당 홈페이지와 페이스북에서 구한 데이터가 대부분을 차지했으며, 정당과 정치인의 블로그 및 각종 회의록, 그리고 청와대에서 수집한 발화 데이터가 그 뒤를 따른다.

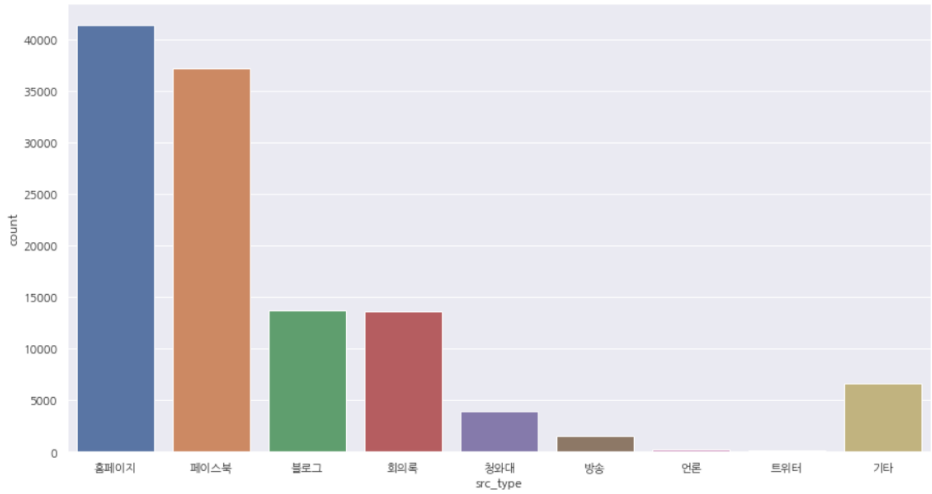


그림 6 출처 별 데이터 수

또한 출처에서 정당이 명시된 경우는 전체 데이터 중 36,296개로, 각 정당에서 발화 데이터가 반영된 내역은 다음과 같다. 앞서 연도에 따른 구성에서 보았듯이 2015년부터 2019년 사이의 발화 데이터가 전체 데이터의 대부분을 구성한만큼, 해당 시기에 활동한 정당들의 발화 데이터가 많이 관측됨을 확인할 수 있다.

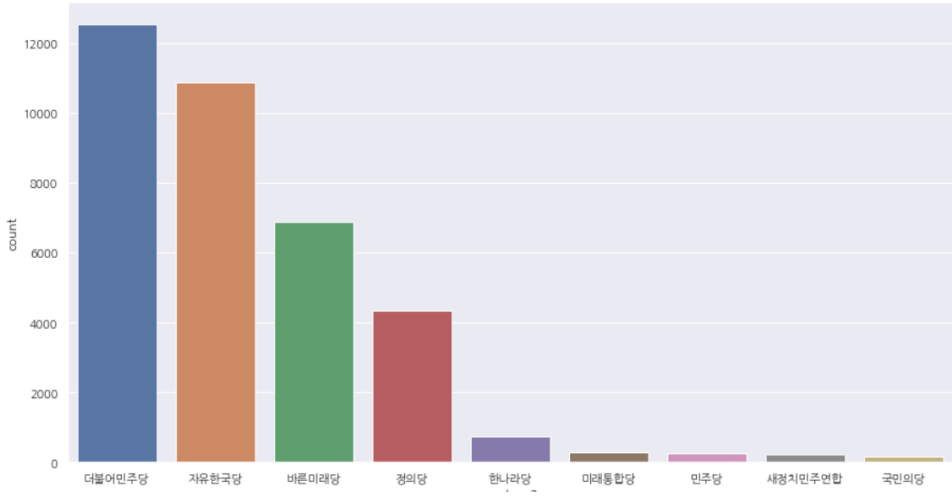


그림 7 출처에 정당이 명시된 경우, 정당에 따른 데이터 수

마지막으로, 문장의 평균 길이는 48.71자, 표준편차는 32.84로 나타났으며, 히스토그램으로 나타내면 아래와 같다. 장문의 문장이 존재하나, 그 수가 상당히 적다. 200자 이상의 문장은 448건으로, 300자 이상의 문장은 55건으로 나타났다.

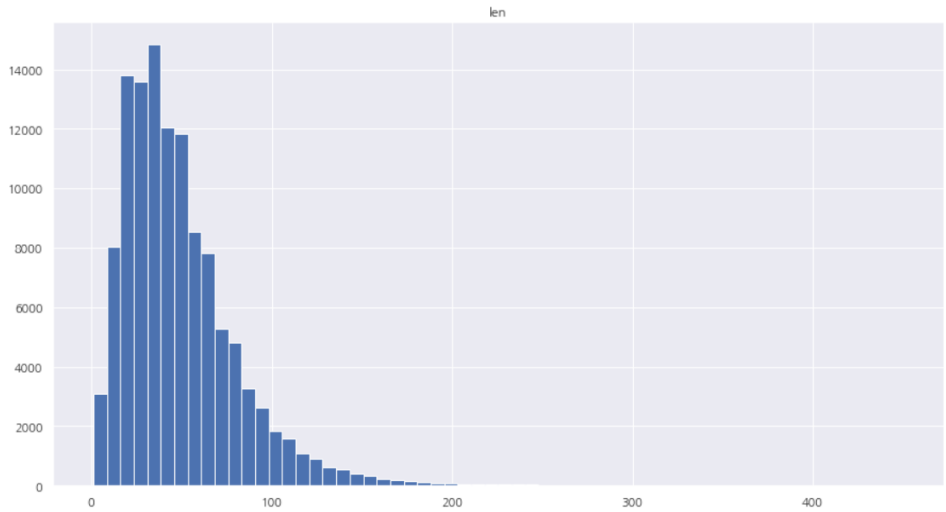


그림 8 문장의 길이에 따른 데이터 분포

제 5 장 연구결과

제 1 절 데이터셋 분할

전체 데이터셋 118,119개를 랜덤하게 학습용 데이터, 검증용 데이터, 평가용 데이터로 분리하였다. 해당 데이터 비율을 나누는 확고한 기준이 존재하지는 않으나, 일반적으로는 6:2:2의 비율을 사용하며, 제작한 데이터의 크기가 크기 때문에 본 연구에서는 학습용 데이터를 늘려 6:1:1의 비율로 데이터를 나누었다. 나누어진 데이터의 크기는 아래와 같다.

데이터셋	크기(개)
학습용 데이터셋(train set)	90,007
검증용 데이터셋(validation set)	14,071
평가용 데이터셋(test set)	14,041

표 7 분할된 데이터셋 크기

각 데이터셋에서 라벨 분포는 다음과 같다.

[학습용 데이터셋]

검증가능성	검증중요성	문장 수(비율)
예	예	15,673(0.1741)
	아니오	12,407(0.1378)
아니오	아니오	61,927(0.6880)
총합		90,007

표 8 학습용 데이터셋의 라벨 구성

[검증용 데이터셋]

검증가능성	검증중요성	문장 수(비율)
예	예	2,572(0.1828)
	아니오	1,399(0.0994)
아니오	아니오	10,100(0.7178)
총합		14,071

표 9 검증용 데이터셋의 라벨 구성

[평가용 데이터셋]

검증가능성	검증중요성	문장 수(비율)
예	예	2,244(0.1589)
	아니오	1,578(0.1124)
아니오	아니오	10,219(0.7278)
총합		14,041

표 10 평가용 데이터셋의 라벨 구성

제 2 절 모델 학습

모델의 입력 데이터는 발화 문장이었으며, 출력 데이터는 두 가지로 검증 가능성에 대한 이진분류 결과와 검증 중요성에 대한 이진분류 결과였다. 각 출력 데이터 종류에 대해서 모델 학습을 진행하였으며, 총 2개의 모델을 훈련하였다.

1) 검증가능성 모델

먼저, 검증가능성의 경우, KoBERT 모델에 이진분류기능을 하는 층 하나를 마지막에 추가하여 학습을 진행하였다. AdamW 옵티마이저(optimizer)를 사용하였으며, 학습률(learning rate)은 5e-

5로 학습을 시켰다. 손실함수는 교차 엔트로피 손실함수를 사용하였으며, 배치 사이즈는 32로 잡았으며, 15 주기동안 학습하였다. KoBERT 내부에서 사용되는 드롭아웃 비율(dropout rate)은 0.5를 사용하였다.

각 주기마다 생성된 모델로 검증용 데이터셋에 대한 예측을 진행시켜보고, 그 결과에 따라 모델을 선정하였다. 주기가 늘어나면서, 모델은 학습용 데이터셋에 과적합되어 학습정확도(train accuracy)는 지속적으로 증가한다. 반면, 검증용 데이터셋에 예측한 결과의 정확도, 정밀도, 재현율, f1-점수를 주기 별로 확인해보면 어느 시점부터 과적합이 일어나는지 확인 가능하다. 아래는 주기별 학습정확도와 검증정확도, 정밀도, 재현율 그리고 f1-점수이다.

epoch	train_acc	valid_acc	valid_pre	valid_rec	valid_f1_
1	0.8812124221	**0.891295084**	**0.7746644597**	0.7928390265	0.7628094333
2	0.9258532783	0.8826581028	0.7300949838	0.8429489393	**0.7631386709**
3	0.94434999	0.8813086709	0.7547359332	0.7881073762	0.7484269557
4	0.9564521863	0.8769762846	0.7247858648	0.8465932077	0.7589528726
5	0.9669793003	0.8762660573	0.7200773626	0.842421662	0.755079265
6	0.9740157305	0.8654428113	0.6887818196	0.8635719481	0.744013033
7	0.9777995989	0.8399024209	0.6296885358	**0.8958563319**	0.7177825012
8	0.9829919125	0.8474030385	0.6434883513	0.8922249918	0.7254839069
9	0.9871356203	0.8481132658	0.6447738152	0.8956919028	0.7279012055
10	0.9893574476	0.8744349061	0.7075624053	0.8582557201	0.7555063549
11	0.9910682545	0.8710258152	0.7002340868	0.8663927175	0.7554946599
12	0.9925235514	0.8771615613	0.7202610366	0.8451813556	0.7581869373
13	**0.9935011554**	0.874107584	0.7092417247	0.8547062835	0.7553451147
14	0.9929345894	0.8805428607	0.7323976324	0.83634632	0.7618629754
15	0.9934456097	0.8820343379	0.7416924425	0.8276652562	0.7628040619

표 11 주기에 따른 검증가능성 모델 학습 결과(train_acc: 학습용 데이터셋 정확도, valid_acc, valid_pre, valid_rec,valid_f1_:각각 검증용 데이터셋 정확도, 정밀도, 재현율, F1-점수)

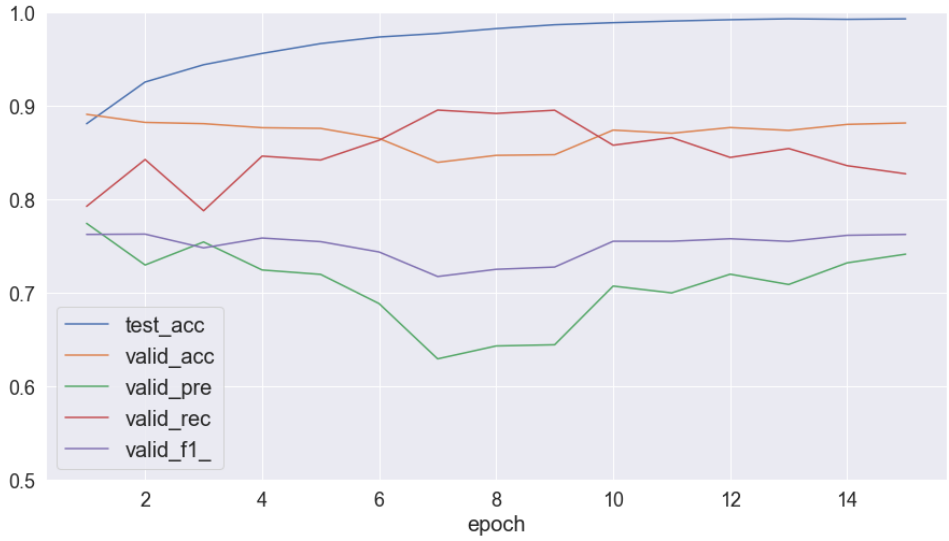


그림 9 주기에 따른 검증가능성 모델 학습 결과

2주기부터 검증용 데이터셋의 정확도가 감소하는 모습이 관측되어, 모델이 학습용 데이터셋에 과적합이 일어난다고 판단하였으며 1주기만 학습한 모델을 최종 검증가능성 모델로 채택하였다. 해당 모델은 검증용 데이터셋에 대한 재현율은 상대적으로 낮지만, 정확도가 가장 뛰어나며, 정밀도와 재현율의 조화평균인 F1-점수가 준수하게 측정되었다.

2) 검증중요성 모델

다음으로 검증중요성에 대해서도 이진분류 모델을 제작하였다. 검증가능성과 비슷하게, KoBERT 모델을 활용하여 이진분류기능을 하는 층 하나를 추가하여 학습을 진행하였다. 마찬가지로, AdamW 옵티마이저(optimizer)를 사용하였으며, 학습률(learning rate)은 5e-5로 학습을 시켰다. 교차 엔트로피 손실함수를 사용하였으며, 배치 사이즈는 32로 잡았으며, 15주기동안 학습하였다. KoBERT 내부에서 사용되는 드롭아웃 비율(dropout rate)은 0.5를 사용하였다. 아래는 학습정확도와 검증용 데이터셋을 활용한 지표이다.

epoch	train_acc	valid_acc	valid_pre	valid_rec	valid_f1_
1	0.8723497465	0.8699450346	0.5638037923	0.7535951888	0.6114377708
2	0.8949611856	**0.8764791255**	**0.5819311681**	0.7226535504	**0.6121275418**
3	0.9205387641	0.8699450346	0.574602645	0.6726913683	0.5852149793
4	0.9382467272	0.8706274704	0.5729774729	0.645583913	0.5705669573
5	0.9408776604	0.8413938982	0.5036405407	0.7749780683	0.5771719838
6	0.9478073463	0.8528285573	0.5286800101	0.734273595	0.57815205
7	0.9603563231	0.8026865119	0.4474001578	**0.8279844653**	0.5496005371
8	0.9699966383	0.8308115119	0.4826031181	0.7461519471	0.5517778475
9	0.9770108502	0.8303143528	0.482963732	0.7600253939	0.5575604922
10	0.9827542736	0.8348598073	0.4896538399	0.749246384	0.5574696659
11	0.9850760831	0.84586833	0.5128498758	0.7213886318	0.5641554208
12	0.9860580341	0.8558547431	0.5371173885	0.6935084484	0.5707565003
13	**0.9864647251**	0.8601161067	0.5464377567	0.6682570564	0.5647023446
14	0.9830807856	0.8642786561	0.5663955484	0.5846832678	0.5365705338
15	0.9834140597	0.8677587698	0.581217292	0.5640681876	0.5333093595

표 12 주기에 따른 검증중요성 모델 학습 결과(train_acc: 학습용 데이터셋 정확도, valid_acc, valid_pre, valid_rec,valid_f1_:각각 검증용 데이터셋 정확도, 정밀도, 재현율, F1-점수)

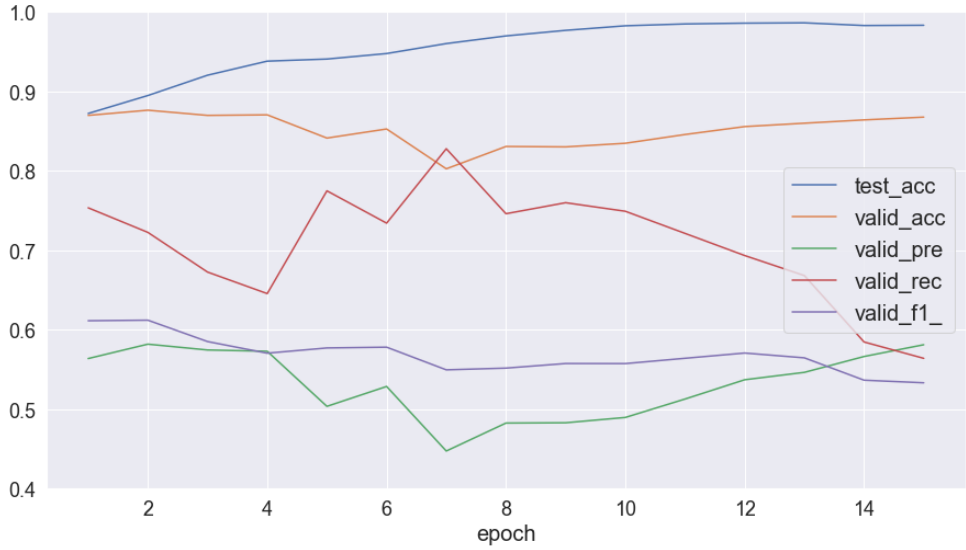


그림 10 주기에 따른 검증중요성 모델 학습 결과

검증용 데이터셋의 지표를 확인한 결과, 3주기부터 학습용 데이터에 과적합이 진행되고 있는 모습을 확인할 수 있었다. 따라서, 과적합이 발생하기 전인 2주기까지 학습한 모델을 최종 모델로 채택하였다. 해당 모델은 분류 정확도가 가장 높았으며, 정밀도와 재현율의 조화평균인 F1-점수도 가장 높게 측정되었다.

제 3 절 모델 평가 및 예측 결과

앞서 학습시킨 모델에 평가용 데이터셋을 넣어 모델을 평가하였다. 학습 과정에서는 훈련용 데이터셋과 검증용 데이터셋만이 관여되어 있으므로, 모델은 평가용 데이터셋을 관측한 적이 없다. 즉, 새로운 데이터셋을 통해, 해당 모델이 일반적인 상황에서도 잘 작동할 수 있는지에 대해 확인이 가능하다.

1) 검증가능성 모델

먼저, 검증가능성 모델은 앞서 채택한 1주기까지 학습한 모델을 이용하였다. 해당 모델을 사용하여 평가용 데이터셋에 대한 예측을 진행해보았다. 아래 표는 모델의 예측 값과 실제 값에 따른 오차 행렬(confusion matrix)이다.

검증가능성		실제 값	
		예	아니오
모델 예측	예	3,163	987
	아니오	659	9,232

표 13 검증가능성 모델 예측 결과 오차 행렬

이에 따라 정확도와 정밀도, 재현율, 그리고 F1-점수를 측정해 본 결과 다음과 같이 나왔다.

정확도(Accuracy)	0.8828
정밀도(Precision)	0.7622
재현율(Recall)	0.8276
F1-점수(F1-Score)	0.7935

표 14 검증가능성 모델 예측 결과

정확도는 전체 데이터 중 모델이 얼마나 정확하게 예측했는지에 관한 지표이다. 검증가능성 모델의 정확도는 0.8828로 분류 성능이 상당히 뛰어나다고 할 수 있다. 모델이 검증가능성을 "예"로 예측한 데이터 중 실제 값이 "예"인 데이터의 비율을 일컫는 정밀도는 0.7622, 실제 검증가능성이 "예"인 데이터 중 모델이 정확하게 예측한 값인 재현율은 0.8276으로 나타났다. 정밀도와 재현율은 한쪽이 높아지면 다른 한쪽이 낮아지기 때문에 이 둘의 조화평균을 이용한 F1-점수를 통해 전반적인 모델의 성능에 대해 이야기할 수 있다. 여기서 구한 검증가능성 모델의 F1-점수는 0.7935이다. F1-점수는 조화평균을 이용하기 때문에 정밀도와 재현율 둘 중 하나라도 낮아지면 그 값에 민감하게 반응한다. 따라서, 모델이 제 1종 오류와 제 2종 오류 중 하나라도 많아진다면 F1-점수는 낮게 나타난다. 따라서 검증가능성 모델은 검증가능성이 "예"인 문장을 "예"로, "아니오"인 문장을 "아니오"로 잘 분류해내고 있다고 볼 수 있다.

실제로 어떤 문장들을 잘 분류하고 있는지 예측 결과를 세부적으로 확인해보았다.

검증가능성 예측이 잘 된 문장 예시

예	(n=3,163) **1) 행적** – 세계 최초로 전자결재문서 원문을 공개했습니다 – 서울시는 모든 행정정보를 시민들께 공개합니다 – 오늘 속초시를 찾아 현장최고위원회의를 했습니다. **2) 발화** – 그런데 고문님의 전략공천에 대해서 정용선 예비후보가 당에서 강하게 반발하고 있더라고요 – 최근 대검도 특별수사부를 운영하는 검찰청을 3개 청으로 축소하겠다는 입장을 이미 밝힌 바 있습니다 **3) 수치 데이터** – 정보소통광장 홈페이지는 5만여건의 행정정보가 열려있습니다 – 노인자살율과 노인빈곤율은 OECD 국가 중 단연 1위입니다
아니오	(n=9,232) **1) 계획 및 공약** – 그래서 저는 KT부지에 문화·예술 시설을 추가 설치하고자 합니다 – 이에 이번 개헌를 통하여 경제 민주화와 토지공개념을 강화하고 실질화 하려고 합니다 **2) 감정 및 의지 표현** – 추운 날씨에도 불구하고 세운상가를 다시 세우는 자리에 함께 해주셔서 감사합니다 – 내년에도 부산항이 세계최고의 항만이 되도록 다함께 파이팅 합시다. **3) 사실적 정보를 포함하지 않은 주장** – 라떼보다 더욱 부드럽고 맛있네요. – 고민정 후보가 자신의 ‘빽’을 자랑한다면 젊은이 답지 못한 거지요 **4) 기타** – 가랑비에 옷 젖는다

표 15 검증가능성 모델 예측이 잘 이루어진 예시

모델이 검증가능성을 “예”로 잘 예측한 문장들의 특징을 정리해 보면 다음과 같다. 우선, 행적에 관한 문장들이다. “~를 했습니다.” 류의 문장을 모델이 잘 분류하고 있었다. 다음은 발화문장이다. 누가 어떤 발언을 했다는 류의 문장, 누군가의 입장이나 행적, 의견 류를 전달하는 문장으로 실제 해당 발언이 있었는지 사실성을 검증할 수 있는 문장들을 모델은 잘 분류해내고 있었다. 마지막으로 수치 데이터를 포함한 문장이다. 통계 데이터 등을 통해 사실성을 검증할 수 있는 문장으로 해당 문장들을 모델은 검증가능성을 “예”로 잘 분류해내고 있었다.

모델이 검증가능성을 “아니오”로 잘 예측한 문장들의 특징을 정리해 보면 다음과 같다. 우선 계획 및 공약에 관한 문장들이다. “~하려고 한다.”, “~할 것이다.”등의 문장들을 “아니오”로 잘 분류해내고 있었다. 또한 감정 및 의지 표현 류의 문장으로 감사나 당혹, 분노 등을 표현하는 문장이나 “~해 나갈 것이다.”등의 문장을 포함한다. 사실적 정보를 포함하지 않은 주장도 “아니오”로 잘 분류하고 있었다.

14,041개의 문장들 중, 12,385개의 문장에 대해 분류가 정확히 잘 일어났고, 특히 팩트체크 검증가능성 데이터는 “아니오”의 비율이 상대적으로 높은 것이 특징이다. 실제로 이후에 팩트체크를 진행해야 하는 데이터는 “예”에 속하는 데이터이기 때문에 “아니오”를 “아니오”로 잘 분류해내는 것만으로도 팩트체크 검증 대상의 범위를 대폭 줄일 수 있다.

모델이 대부분의 문장을 잘 분류해내고 있지만, 한계는 존재한다. 해당 모델의 한계를 확인하기 위하여 잘못 예측한 결과도 확인하여 보았다.

검증가능성	예측이 틀린 문장 예시
Type I Error	(n=987) – 1시간 대기 3분 진료는 일상이 되었습니다 – 장관을 마치고 대구로 돌아와 보니 분위기가 심각했습니다 – 이희호 여사님의 방북조차 기회로 살리지 못했다 **라벨링 오류(실제 값이 “예”)** – 검찰이 소환 준비도 하지 않은 상황인데 자진해서 출두한 것이다 – 이번에 총선 앞두고 김조광수 감독님과 이자스민 의원도 모셨습니다 – 그리고 김정숙 여사에게 마이크를 넘겼습니다
Type II Error	(n=659) – 전 국민이 모두다 저 국회의원이 찬성했는지, 반대했는지 알 수 있다 – 참좋은지방정부위원회에 대해서 간단히 소개 말씀드렸습니다 – 재단설립, 출연금 모금, 운영까지 의혹이 한두 가지가 아닙니다.

표 16 검증가능성 모델 예측이 잘 이루어지지 않은 예시

딥러닝의 특성상, 모델이 어떤 내용을 기반으로 해당 문장들에서 오류를 일으켰는지 확실하게 확인은 어렵다. 하지만, 현재 제작한 모델이 어떤 종류의 문장에서 한계를 보이는지 확인은 할 수 있었다. 모델은 “예”라고 예측하였지만 실제 검증가능성이 “아니오”인 제1종 오류를 범한 문장에서는 구체적인 검증 대상이 되는 사실 정보가 없지만 설명으로 보이거나, 수사적 표현을 일부 포함하는 등 설명 형태의 문장을 찾아볼 수 있었다. 또한 비슷하지만 일부 데이터셋 오류를 발견할 수 있었다. 반면, 모델이 “아니오”로 예측했지만 실제 검증가능성이 “예”인 제2종 오류 문장의 예시는 위의 표에서 확인할 수 있다.

2) 검증중요성 모델

검증중요성 모델은 앞서 채택한 2주기까지 학습한 모델을 이용하였다. 해당 모델을 사용하여 평가용 데이터셋에 대한 예측을 진행해보았다. 아래 표는 모델의 예측 값과 실제 값에 따른 오차 행렬(confusion matrix)이다.

검증중요성		실제 값	
		예	아니오
모델 예측	예	1,861	1,501
	아니오	383	10,296

표 17 검증중요성 모델 예측 결과 오차 행렬

이에 따라 정확도와 정밀도, 재현율, 그리고 F1-점수를 측정해 본 결과 다음과 같이 나왔다.

정확도(Accuracy)	0.8658
정밀도(Precision)	0.5535
재현율(Recall)	0.8293
F1-점수(F1-Score)	0.6639

표 18 검증중요성 모델 예측 결과

정확도는 전체 데이터 중 모델이 얼마나 정확하게 예측했는지에 관한 지표이다. 검증중요성 모델의 정확도는 0.8658로 분류 성능이 상당히 뛰어나다고 할 수 있다. 모델이 검증중요성을 "예"로 예측한 데이터 중 실제 값이 "예"인 데이터의 비율을 일컫는 정밀도는 0.5535, 실제 검증중요성이 "예"인 데이터 중 모델이 정확하게 예측한 값인 재현율은 0.8293으로 나타났다. 검증중요성 모델의 F1-점수는 0.6639이다. 검증중요성 모델은 재현율은 높지만 정밀도가 조금 낮게 나와 F1-점수 또한 낮아지는 예측 결과를 보여주었다. 즉, 모델이 "예"라고 예측한 결과 중 실제로 검증중요성이 "예"인 비율이 조금 낮았다. 반면, 모델이 "아니오"라고 예측한 내용의 실제 값은 대부분 "아니오"라고 볼 수 있다.

실제로 어떤 문장들을 잘 분류하고 있는지 예측 결과를 세부적으로 확인해보았다.

검증중요성　예측이 잘 된 문장 예시

예	(n=1,861) **1) 법률** – 우리 대한민국헌법 31조를 보면 교육의 정치적인 중립성에 대해서 쓰여 있습니다 – 인사청문회법 제9조 3항은 국회인사청문회가 정당한 이유 없이 기간 내에 임명 동의안에 대한 심사나 인사 청문을 마치지 않을 경우 의장이 이를 바로 본회의에 부의할 수 있다고 명시하고 있다 – 같은 조 4항에서도 '제1항의 사유가 있는 의원은 그 사안에 한정하여 위원회의 허가를 받아 감사 또는 조사를 회피할 수 있다'고 법률로 정하고 있다 **2) 행적** – 우선 2014년 1월에 교육부에서 역사 교과서 발행체제 개편을 위한 자율팀이 만들어지고 그리고 그다음 달에 청와대 비서관회의와 연계하겠다는 방침이 정해집니다 – 심지어 민주당은 자신들이 원하는 법안은 합의를 포기한 채 표결로 강행처리하고 있다 – 노무라증권은 2.4%에서 1.8%로 0.6%나 조정했다. – 법원이 조국 前 민정수석의 구속영장을 기각했다 **3) 정책 효과** – 양질의 정규직 일자리가 35만개나 사라졌습니다
아니오	(n=10,296) **1) 검증가능성이 "아니오" 인 경우** – 경제원로들까지 비판한 소득주도성장, 소귀에 경 읽기가 되지 않기를 바란다 – 그외 민생·개혁 법안 처리를 위해 4월 임시국회가 즉각

	소집되어야 한다. - 6.25 전쟁의 통한의 상처가 오롯이 새겨진 70년이다 **2) 단순한 설명** - 11월 9일이다 - 요즘에는 이 곳에 하루 400명 정도가 방문한다고 합니다

표 19 검증중요성 모델 예측이 잘 이루어진 예시

모델이 검증중요성을 “예”로 잘 예측한 문장들의 특징을 정리해 보면 다음과 같다. 우선, 법률 정보에 관한 문장들이다. 이는 위법성 등에 대한 판단을 할 수 있는 중요한 정보이다. 따라서 해당 문장은 팩트체크의 주요 대상이 되고 이를 모델이 잘 분류하고 있었다. 또한 사실성이 대중에게 중요한 정보를 지닌 행적에 대한 내용도 잘 분류된 내역을 확인할 수 있었다. 정치인의 정치 행보는 일반 대중의 삶에 영향을 미칠 수 있기 때문에 해당 내용의 사실성을 검증할 필요가 있으며 이런 문장들이 잘 분류된 결과를 볼 수 있었다. 또한 정책 효과에 관한 내용도 사람들의 정책에 대한 판단 결과에 영향을 미칠 수 있기에 그 사실성이 중요하다고 볼 수 있는데, 해당 내용을 가진 문장의 검증중요성을 잘 분류한 사례들을 확인할 수 있었다.

모델이 검증중요성을 “아니오”로 잘 예측한 문장들의 대다수는 검증가능성이 “아니오”인 문장들이었다. 검증이 가능하지 않은 형태의 문장들은 사실성을 평가할 수 없기 때문에 검증중요성 또한 “아니오"로 분류되는 것이 맞다. 또한 검증이 가능한 형태이더라도 단순한 설명을 포함한 문장을 “아니오”로 잘 분류해내고 있었다.

14,041개의 문장들 중, 12,751개의 문장에 대해 분류가 정확히 잘 일어났고, 검증중요성 기준 또한 검증가능성 기준과 마찬가지로 검증중요성이 “예”인 문장을 대상으로 팩트체크를 진행하기 때문에 “아니오”를 “아니오”로 잘 분류해내는 것만으로도 팩트체크 검증 대상의 범위를 대폭 줄일 수 있다.

모델이 대부분의 문장을 잘 분류해내고 있지만, 한계는 존재한다. 특히 정밀도가 조금 낮게 나왔기에 모델이 어떤 문장들을 잘못 분류하고 있는지 데이터셋을 확인해 보았다.

검증중요성	예측이 틀린 문장 예시
Type I Error	(n=1,501) **1) 행적** – 어제 삼일절태극기집회 전성기때만큼 엄청난 인파가 몰렸다 – 오늘 오전 세계최장기 고공농성을 갱신한 파인텍 관련 노사대표자들이 만납니다 – 허태정후보 병역의혹 규명 시민검증단 모집 – 문재인 대통령은 이주열 신임 한국은행 총재에게 임명장을 수여했습니다
Type II Error	(n=383) **1) 정책 효과** – 주휴수당은 1인 이상 사업장 전체에 적용되어 대기업, 중소기업 할 것 없이 모든 노동자들에게 적용되기 때문에 대한민국 2천만 노동자 모두의 임금이 삭감될 것이다 – 2006년 ‘바다이야기’ 사태가 터지면서 게임산업은 직격탄을 맞았습니다 **2) 법률** – 대통령의 개헌안은 국회에서 수정할 수 없습니다. – 헌법 제130조에 의하면 국회는 헌법개정안이 공고된 날로부터 60일 이내에 의결하여야 한다 **3) 라벨링 오류(실제 값이 “아니오”)** – 북한이 품목을 문제 삼아서 지원을 거절한 것은 아쉬운 일이다 –2025년에는 인구의 20%에 육박할 전망이다

표 20 검증중요성 모델 예측이 잘 이루어지지 않은 예시

모델은 “예”라고 예측하였지만 실제 검증중요성이 “아니오”인 제1종 오류를 범한 문장이 많아 정밀도 수치가 비교적 낮게 나왔다고 할 수 있다. 이는 대부분 행적에 관한 문장으로 이들의 검증가능성은 “예”이지만, 사람들은 여기에 해당하는 비교적 사소한 문장의 사실성 여부를 중요하게 여기지 않는 내용이다. 즉, 행적을 다루는 데이터의 분류에서 검증중요성을 “예”라고 판단하는 경향 이 있는 모델이라고 볼 수 있다. 반면, 모델이 “아니오”로 예측했지만 실제 검증가능성이 “예”인 제2종 오류 문장의 예시는 주로 정책 효과나 법률, 그리고 사람의 라벨링 오류로 구성되어 있었다. 재현율이 높아 그 수는 적지만, 이후 팩트체크 과정에서 검증중요성이 “예”로 분류된 문장을 팩트체크한다는 가정 하에서는 이런 문장을 제외하는 것이 오히려 팩트체크 모델의 약점이 될 수 있기에 팩트체크 과제의 특성 상 정밀도가 낮아도 재현율이 높은 현재 모델이 좋은 모델이라고 볼 수 있다.

종합하면, 검증가능성(Accuracy: 0.8828, F1-Score: 0.7935)과 검증중요성 모델(Accuracy: 0.8658, F1-Score: 0.6639) 모두 상당히 높은 정확도를 지닌 분류결과를 보여주었다. 검증가능성 모델은 정확도뿐만 아니라 정밀도와 재현율, F1-점수까지 높아 뛰어난 분류 성능을 지닌 모델이라고 할 수 있다. 검증중요성 모델은 정밀도가 조금 낮았지만, 재현율이 높아 검증중요성이 낮은 문장을 일차적으로 분류하는 데 좋은 모델임을 확인할 수 있었다.

제 6 장 논의 및 결론

제 1 절 연구내용 요약

디지털 시대의 도래로 인해, 전통적인 미디어의 정보 생산자이자 전달자 역할이 줄어들게 되면서 유통되는 정보의 사실성을 검증하는 팩트체크에 대한 수요와 중요성이 강조되었다. 현재 이루어지고 있는 팩트체크 방식은 대부분 전문가에 의해 직접 이루어지고 있어, 허위정보에 발빠르게 대처하는 데 어려움이 있으며 전체적으로 다룰 수 있는 정보의 양이 제한되어 있다. 이에 팩트체크 과정을 자동화하려는 시도가 등장하고 있다. 특히 자연어 처리 기술과 딥러닝 언어모델의 발달으로 보다 복잡한 자연어 과제를 인공지능이 잘 수행할 수 있게 됨에 따라, 그 가능성을 실질적으로 탐구해보는 것이 필요하였다.

본 연구에서는 팩트체크의 세부 단계 중 하나인 검증대상 선정 과정에 집중하였다. 우선 팩트체크 검증대상이 되는 문장을 분류하기 위한 두 가지 기준을 “검증가능성”과 “검증중요성”으로 정리하였다. 검증가능성은 문장의 형식적 특성에 따라 어느 정도 분류가 되는 한편, 검증중요성은 내용에 대한 인간의 판단에 의존하는 측면이 있기 때문에 두 개의 라벨을 분리하였다. 검증가능성은 문장이 사실적 정보를 포함하고 있는가에 대한 분류이며, 검증중요성은 문장이 실제 팩트체크의 대상이 되는, 일반대중이 해당 내용의 참거짓에 관심을 가질 것인가에 대한 분류이다. 각 기준은 “예”와 “아니오”의 이진 라벨로 분류할 수 있었다.

기존에 팩트체크 검증대상 분류를 위한 데이터셋은 주로 영어 등 외국어로 이루어져 있었다(Hassan, Arslan, et al., 2017; Nakov et al., 2021). 하지만 이를 그대로 가져오기에는 한국어와 영어의 언어적 구성이 다를 뿐만 아니라, 정치적 맥락 상황을 고려하는 것이 필요했기에 자체적인 데이터를 필요로 했다. 일부 연구에서는 기존 전문가들이 팩트체크한

대상을 팩트체크가 필요한 문장, 그 외의 문장은 필요하지 않은 문장으로 분류하여 연구를 진행하였다. 하지만 이렇게 형성된 데이터는 일부 팩트체크가 필요한 문장만에 대한 데이터일 뿐이며, 어떤 문장이 팩트체크의 대상에서 제외되었는지에 대한 이야기를 하기 어렵다. 따라서, 본 연구에서는 직접 정치적 논의를 이해할 수 있으며 한국어 이해도가 높은 연구참여자(N=15)를 모집하여 데이터셋을 제작하였다.

형성된 데이터셋은 총 118,119개의 문장으로 이루어져 있으며, 각 문장당 검증가능성과 검증중요성 두 개의 이진 라벨을 지니고 있다. 해당 문장은 1997년부터 2020년 3월까지 정치인이 청와대 홈페이지, 정당의 보도자료나 논평, 개인 및 정당 SNS 등지에서 발화한 내역으로 이루어져 있다. 문장의 평균 길이는 48.71자, 표준편차는 32.84로 나타났다.

해당 데이터셋을 이용하여, 실질적으로 딥러닝 모델을 이용해 주장 판별이 가능한지 확인해보기 위하여 검증대상 분류 모델을 제작하였다. 한국어 딥러닝 언어모델 중 BERT를 기반으로 만들어진 한국어 처리에 상당히 뛰어난 능력을 보이고 있는 KoBERT 모델을 이용하였다. 해당 모델은 이미 대용량의 한국어 코퍼스를 사전학습한 모델로, 이를 이용하면 비교적 적은 데이터로도 원하는 과제를 수행하도록 전이학습을 시킬 수 있다.

검증가능성과 검증중요성 두 가지 라벨에 대해 각각 이진 분류 모델을 제작하였으며, 그 성능을 정확도, 정밀도, 재현율, F1-점수를 통해 확인한 후, 잘 분류되거나 잘 분류되지 않은 문장들이 어떤 문장들인지 확인해 보았다.

평가 데이터셋을 활용해 측정한 검증가능성 모델의 정확도(Accuracy)는 0.8828, 정밀도(Precision)는 0.7622, 재현율(Recall)은 0.8276, F1-점수(F1-score)는 0.7935로 측정되었다. 실제 평가 데이터 분류 결과를 검토한 결과, 실제 검증가능성이 “아니오”인 계획 및 공약, 감정 및 의지 표현, 사실적 정보를 포함하지 않은 주장들을 “아니오”로 잘 분류하고 있었으며 행적이나 발화, 수치 데이터 등 검증가능성이 “예”인 문장들 또한 잘 분류되고 있었다.

검증중요성 모델의 정확도(Accuracy)는 0.8658, 정밀도(Precision)는 0.5535, 재현율(Recall)은 0.8293, F1-점수(F1-score)는 0.6639로 측정되었다. 실제 평가 데이터 분류 결과를 검토한 결과, 실제 검증중요성이 "아니오"인 검증가능성이 "아니오"인 문장들과 단순한 설명 류의 문장은 "아니오"로 잘 분류하고 있었다.

검증중요성이 "예"인 문장은 법률이나 중요한 행적, 정책 효과에 관한 문장인데, 법률에 대한 문장은 비교적 "예"로 잘 분류하는 반면, 정책 효과에 대한 문장은 그 수가 적지만 "아니오"로 분류하는 경우를 찾아볼 수 있었다. 또한, 행적에 관한 문장에 있어서 어떤 내용이 검증이 필요한 중요한 문장인지 모델의 분류 성능이 제한되는 모습을 발견할 수 있었다. 특히 이런 행적에 관한 문장으로 인해 검증중요성 모델의 정밀도가 상대적으로 낮게 나온 모습을 볼 수 있었다.

제 2 절 논의

본 연구는 실제 팩트체크 검증대상 분류를 위한 한국어 데이터셋을 직접 제작했다는 데에 큰 의의가 있다. 해당 데이터셋은 실제 팩트체크 뉴스의 대상으로 주로 선정되는 정치인 발화 데이터로 구성되어 있다. 또한, SNS, 국회회의록, 정당 논평 등 다양한 출처와 1997년~2020년까지 상당히 긴 시간 동안 축적된 데이터로 구성되어 있다. 이는 최초로 한국어 팩트체크 문장 선정을 위한 유의미한 크기의 데이터셋을 구축했다고 볼 수 있다. 이는 이후 팩트체크에 대한 연구를 진행할 연구자들이 활용할 수 있는 데이터로 활용될 수 있을 뿐만 아니라, 인공지능 분야에서 한국어 자연어 처리를 위한 데이터셋으로도 활용될 수 있다.

해당 데이터셋은 실제로 검증대상 기준이 되는 두 가지 특성인 검증가능성과 검증중요성을 따로 고려하여 라벨링이 되었다. 한 가지 아쉬운 점은, 해당 기준을 세울 때 실제 팩트체크를 진행하는 전문가의 판단을 고려하는 부분이 부족했다는 점이다. 기존 라벨링 데이터셋 분류

기준과 팩트체크 뉴스 및 연구를 참고했지만, 실제로 현업에서 일하는 전문가들의 의견을 라벨 및 데이터셋 제작에 반영했으면 더 좋은 품질의 데이터를 제작할 수 있었을 것이다. 또한, 전체 라벨링 과정이 비대면 세션으로 이루어져서 이후, 모델의 예측 결과를 확인할 때 일부 잘못 라벨링한 결과를 발견하기도 하였다. 대면으로 워크숍을 진행하였다면 보다 높은 품질의 데이터셋을 만들어낼 수 있었을 것이다.

또한, 발언 시기에 편향성이 존재한다는 점이 해당 데이터셋의 한계라고 볼 수 있다. 시기에 따라 문장의 검증중요성은 얼마든지 달라질 수 있을 뿐만 아니라, 현재 제작된 데이터셋에서 다루고 있는 주제가 아닌 새로운 주제가 다량 등장할 경우, 대표성 있는 데이터셋으로 보기 어려워질 수도 있기에 지속적으로 업데이트 해줄 필요성이 존재한다.

또한 제작한 데이터셋을 바탕으로 알고리즘이 팩트체크 검증대상이 되는 주장(claim)을 판별해낼 수 있음을 밝혔다. 다량의 텍스트가 주어졌을 때 주장을 판별해내는 것은 팩트체크 자동화를 위한 필요조건이다. 알고리즘을 통해 팩트체크의 대상이 되는 주장을 판별하는 것은 기존 전문가 팩트체크 과정을 간소화하는 데 도움이 될 수 있을 뿐만 아니라, 추후 범람하는 데이터 속에서 알고리즘이 팩트체크 대상 선정부터 사실성 확인까지 팩트체크의 전 과정을 수행할 수 있는 핵심 기법 중 하나이다.

본 연구에서는 주장 판별을 위해 두 가지 기준으로 검증대상을 분류할 수 있는 모델을 제작하였다. 각 모델은 검증가능성과 검증중요성을 기준으로 상당히 정확한 수준으로 문장을 분류해낼 수 있었다. 검증가능성 모델은 정확도와 정밀도, 재현율, F1-점수가 모두 높게 측정되었다. 이는 문장이 사실에 관한 주장을 포함하고 있는지에 대한 기준을 알고리즘이 잘 판별하고 있다고 보인다. 검증중요성을 학습한 분류 모델 또한 상당히 정확한 수준으로 중요한 문장을 잘 분류해내고 있었다.

두 모델은 딥러닝을 활용한 사전학습 언어모델을 이용하여 학습되었으며, 그 결과 비교적 간단한 전이학습 모델로도 상당히 좋은 성능을 낼 수 있는 모델을 제작할 수 있었다. 이는 딥러닝 알고리즘이 추후

팩트체크 자동화 과정에서 실질적으로 팩트체크 대상이 되는 주장을 판별하는 데 쓰일 수 있다는 점을 의미한다.

검증가능성 모델의 전반적인 성능 지표가 높게 나온 것에 비해, 검증중요성 모델은 정확도는 높게 나온 것에 비해 정밀도가 상대적으로 떨어지는 모습을 보이는 것이 아쉬운 점이다. 하지만 추후 모델의 성능을 높이기 위하여 사용되는 다양한 기법을 적용해 본다면, 해당 모델을 개선할 수 있을 것이다.

마지막으로, 최근 AI-사람 협업 모델에 관한 연구들이 이루어지고 있다. 팩트체크 과제에서도 연구에서 제시한 자동화 모델이 실제 사용되는 상황에 대한 연구를 할 수 있을 것이다. 사람들이 본 연구에서 제작한 분류 모델을 활용한다면 팩트체크할 문장을 선정하는 과정에서 체크해야 할 문장의 수를 획기적으로 줄이는 방향으로 활용될 수 있으며, 이는 범람하는 정보를 일차적으로 걸러줌으로써 더 효율적인 팩트체크 방식을 구축하는 데 사용될 수 있다고 생각한다. 하지만, 해당 모델이 분류 과정에서 뛰어난 성능을 보이는 것과 별개로 알고리즘을 이용한 분류 모델을 실제 팩트체크 과정에서 사용해보고, 이런 인공지능 기법이 사람의 작업을 효율적으로 바꿔주는지 확인해 보는 것이 추후에 필요한 연구이다.

참고 문헌

마동훈, 오택섭, 김선혁, & 김해영. (2013). 저널리즘 공공성 실현을 위한 한국형 팩트체킹 모델 연구. 서울: 한국언론진흥재단.

박아란, 이나연, & 정은령. (2018). 팩트체크 저널리즘의 주요 원칙. 서울: 한국언론진흥재단.

이나연. (2018). 한국 언론의 팩트체크: 19 대 대통령선거에서의 후보자 검증 기사를 중심으로. 언론정보연구, *55*(4), 99–138.

전영호. (2019). BERT Transformer 와 Deep Learning 을 활용한 전이학습 효과 검증 연구: 법률상담데이터 분류문제 적용. 한국경영공학회지, *24*(4), 77–89.

정은령. (2017). 팩트체킹 뉴스 의미와 한계. 관훈저널, *143*, 19–25.

정은령. (2019). 팩트체크 뉴스와 한국 방송 저널리즘의 신뢰 회복: 방송기자들의 팩트체크 뉴스 양식과 뉴스 가치에대한 인식을 중심으로. 방송문화연구, *31*(1), 47–101.

최순욱, & 윤석민. (2017). 협업형 사실검증 서비스의 의의와 과제 : 〈 SNU팩트체크 〉 의 사례. 사이버커뮤니케이션학보, *34*(2), 173–205.

황상흠 & 김도현. (2020). 한국어 기술문서 분석을 위한 BERT 기반의 분류모델. 한국전자거래학회지, *25*(1), 203–214.

Amazeen, M. A. (2015). Revisiting the epistemology of fact-checking.

Critical Review, *27*(1), 1–22.

Amazeen, M. A. (2020). Journalistic interventions: The structural factors affecting the global emergence of fact-checking. *Journalism*, *21*(1), 95–111. https://doi.org/10.1177/1464884917730217

Amazeen, M. A., Thorson, E., Muddiman, A., & Graves, L. (2018). Correcting political and consumer misperceptions: The effectiveness and effects of rating scale versus contextual correction formats. *Journalism & Mass Communication Quarterly*, *95*(1), 28–48.

Arslan, F., Hassan, N., Li, C., & Tremayne, M. (2020). A Benchmark Dataset of Check-worthy Factual Claims. *arXiv:2004.14425 [cs]*. http://arxiv.org/abs/2004.14425

Atanasova, P., Barron-Cedeno, A., Elsayed, T., Suwaileh, R., Zaghouani, W., Kyuchukov, S., Martino, G. D. S., & Nakov, P. (2018). Overview of the CLEF-2018 CheckThat! Lab on Automatic Identification and Verification of Political Claims. Task 1: Check-Worthiness. *arXiv:1808.05542 [cs]*. http://arxiv.org/abs/1808.05542

Atanasova, P., Nakov, P., Karadzhov, G., & Mohtarami, M. (일자 없음). *Overview of the CLEF-2019 CheckThat! Lab: Automatic Identification and Verification of Claims. Task 1: Check-Worthiness*. 15.

Atanasova, P., Nakov, P., Màrquez, L., Barrón-Cedeño, A., Karadzhov, G., Mihaylova, T., Mohtarami, M., & Glass, J. (2019). Automatic Fact-Checking Using Context and Discourse Information. *Journal of*

Data and Information Quality (JDIQ), *11*(3), 12.

Ciampaglia, G. L., Shiralkar, P., Rocha, L. M., Bollen, J., Menczer, F., & Flammini, A. (2015). Computational Fact Checking from Knowledge Networks. *PLOS ONE*, *10*(6), e0128193. https://doi.org/10.1371/journal.pone.0128193

Cohen, S., Hamilton, J. T., & Turner, F. (2011). Computational journalism. *Communications of the ACM*, *54*(10), 66–71.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. https://arxiv.org/abs/1810.04805v2

Garg, S., Vu, T., & Moschitti, A. (2019). Tanda: Transfer and adapt pre-trained transformer models for answer sentence selection. *arXiv preprint arXiv:1911.04118*.

Graves, L. (2017). Anatomy of a fact check: Objective practice and the contested epistemology of fact checking. *Communication, Culture & Critique*, *10*(3), 518–537.

Graves, L. (2018). Understanding the promise and limits of automated fact-checking. *Factsheet, 2*, 2018–02.

Graves, L., & Amazeen, M. A. (2019). Fact-Checking as Idea and Practice in Journalism. In *Oxford Research Encyclopedia of Communication*.

Graves, L., & Glaisyer, T. (2012). The fact-checking universe in spring 2012. *New America*.

Hansen, C., Hansen, C., Simonsen, J., & Lioma, C. (2019). Neural weakly

supervised fact check-worthiness detection with contrastive sampling-based ranking loss. *20th Working Notes of CLEF Conference and Labs of the Evaluation Forum, CLEF 2019Conference and Labs of the Evaluation Forum, 2380*.

Hassan, N., Adair, B., Hamilton, J. T., Li, C., Tremayne, M., Yang, J., & Yu, C. (2015). *The Quest to Automate Fact-Checking*. 5.

Hassan, N., Arslan, F., Li, C., & Tremayne, M. (2017). Toward automated fact-checking: Detecting check-worthy factual claims by ClaimBuster. *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1803–1812.

Hassan, N., Li, C., & Tremayne, M. (2015). Detecting check-worthy factual claims in presidential debates. *Proceedings of the 24th acm international on conference on information and knowledge management*, 1835–1838.

Hassan, N., Nayak, A. K., Sable, V., Li, C., Tremayne, M., Zhang, G., Arslan, F., Caraballo, J., Jimenez, D., Gawsane, S., Hasan, S., Joseph, M., & Kulkarni, A. (2017). ClaimBuster: The first-ever end-to-end fact-checking system. *Proceedings of the VLDB Endowment*, *10*(12), 1945–1948. https://doi.org/10.14778/3137765.3137815

Hassan, N., Tremayne, M., Arslan, F., & Li, C. (2016). Comparing automated factual claim detection against judgments of journalism organizations. *Computation+ Journalism Symposium*.

Hassan, N., Yousuf, M., Mahfuzul Haque, M., A Suarez Rivas, J., &

Khadimul Islam, M. (2019). Examining the Roles of Automation, Crowds and Professionals Towards Sustainable Fact-checking. *Companion Proceedings of The 2019 World Wide Web Conference*, 1001–1006.

Hidey, C., & Diab, M. (2018). Team SWEEPer: Joint Sentence Extraction and Fact Checking with Pointer Networks. *Proceedings of the First Workshop on Fact Extraction and VERification (FEVER)*, 150–155.

Karadzhov, G., Nakov, P., Màrquez, L., Barrón-Cedeño, A., & Koychev, I. (2017). Fully automated fact checking using external sources. *arXiv preprint arXiv:1710.00341*.

Konstantinovskiy, L., Price, O., Babakar, M., & Zubiaga, A. (2018). Towards automated factchecking: Developing an annotation schema and benchmark for consistent automated claim detection. *arXiv preprint arXiv:1809.08193*.

Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. *Advances in neural information processing systems*, 1097–1105.

Liu, X., He, P., Chen, W., & Gao, J. (2019). Multi-task deep neural networks for natural language understanding. *arXiv preprint arXiv:1901.11504*.

Ma, J., Gao, W., Joty, S., & Wong, K.-F. (2019). *Sentence-Level Evidence Embedding for Claim Verification with Hierarchical Attention Networks*.

Mihaylova, T., Karadjov, G., Atanasova, P., Baly, R., Mohtarami, M., & Nakov, P. (2019). SemEval-2019 task 8: Fact checking in community question answering forums. *arXiv preprint arXiv:1906.01727*.

Minaee, S., Kalchbrenner, N., Cambria, E., Nikzad, N., Chenaghlu, M., & Gao, J. (2020). Deep Learning Based Text Classification: A Comprehensive Review. *arXiv:2004.03705 [cs, stat]*. http://arxiv.org/abs/2004.03705

Nakov, P., Barrón-Cedeño, A., Elsayed, T., Suwaileh, R., Màrquez, L., Zaghouani, W., Atanasova, P., Kyuchukov, S., & Da San Martino, G. (2018). Overview of the CLEF-2018 CheckThat! Lab on automatic identification and verification of political claims. *International Conference of the Cross-Language Evaluation Forum for European Languages*, 372–387.

Nakov, P., Da San Martino, G., Elsayed, T., Barrón-Cedeño, A., Míguez, R., Shaar, S., Alam, F., Haouari, F., Hasanain, M., & Babulkov, N. (2021). The CLEF-2021 CheckThat! Lab on detecting check-worthy claims, previously fact-checked claims, and fake news. *European Conference on Information Retrieval*, 639–649.

Nyhan, B., & Reifler, J. (2015). The effect of fact-checking on elites: A field experiment on US state legislators. *American Journal of Political Science*, *59*(3), 628–640.

Patwari, A., Goldwasser, D., & Bagchi, S. (2017). Tathya: A multi-classifier

system for detecting check-worthy statements in political debates. *Proceedings of the 2017 ACM on Conference on Information and Knowledge Management*, 2259–2262.

Pavlik, J. (2000). The impact of technology on journalism. *Journalism studies*, *1*(2), 229–237.

Peters, M. E., Neumann, M., Iyyer, M., Gardner, M., Clark, C., Lee, K., & Zettlemoyer, L. (2018). Deep contextualized word representations. *arXiv:1802.05365 [cs]*. http://arxiv.org/abs/1802.05365

Pingree, R. J., Brossard, D., & McLeod, D. M. (2014). Effects of journalistic adjudication on factual beliefs, news evaluations, information seeking, and epistemic political efficacy. *Mass Communication and Society*, *17*(5), 615–638.

Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). *Improving language understanding by generative pre-training*.

Schudson, M. (2001). The objectivity norm in American journalism. *Journalism*, *2*(2), 149–170.

Schudson, M., & Anderson, C. (2009). Objectivity, professionalism, and truth seeking in journalism. In *The handbook of journalism studies* (pp 108–121). Routledge.

Sun, C., Qiu, X., Xu, Y., & Huang, X. (2019). How to Fine-Tune BERT for Text Classification? In M. Sun, X. Huang, H. Ji, Z. Liu, & Y. Liu (편집자), *Chinese Computational Linguistics* (pp 194–206). Springer International Publishing. https://doi.org/10.1007/978-3-

030-32381-3_16

Thorne, J., & Vlachos, A. (2018). Automated fact checking: Task formulations, methods and future directions. *arXiv preprint arXiv:1806.07687*.

Thorne, J., & Vlachos, A. (2017). An extensible framework for verification of numerical claims. *Proceedings of the Software Demonstrations of the 15th Conference of the European Chapter of the Association for Computational Linguistics*, 37–40.

Thorne, J., Vlachos, A., Christodoulopoulos, C., & Mittal, A. (2018). FEVER: A large-scale dataset for Fact Extraction and VERification. *arXiv:1803.05355 [cs]*. http://arxiv.org/abs/1803.05355

Thorne, J., Vlachos, A., Cocarascu, O., Christodoulopoulos, C., & Mittal, A. (2018). The fact extraction and verification (fever) shared task. *arXiv preprint arXiv:1811.10971*.

Uscinski, J. E., & Butler, R. W. (2013). The epistemology of fact checking. *Critical Review*, *25*(2), 162–180.

Vlachos, A., & Riedel, S. (2014). Fact Checking: Task definition and dataset construction. *Proceedings of the ACL 2014 Workshop on Language Technologies and Computational Social Science*, 18–22. https://doi.org/10.3115/v1/W14-2508

Vlachos, A., & Riedel, S. (2015). Identification and verification of simple claims about statistical properties. *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*,

2596–2601.

Wang, W. Y. (2017). “ liar, liar pants on fire”: A new benchmark dataset for fake news detection. *arXiv preprint arXiv:1705.00648*.

Abstract

Deep Learning-Based Check-worthy claim detection for Automated Fact-checking

Sung Min Park
Department Of Communications
The Graduate School
Seoul National University

This study attempted to automate the process of detecting check-worthy claims during the fact-checking process. Specifiaclly, we constructed a dataset to classify check-worthy claims, and based on this, we built a classification model using pre-trained deep learning language model.

Our dataset consists of a total of 118,119 sentences and was produced based on past Korean politicians' utterance data (including websites, SNS, and minutes of the National Assembly). Each sentence has two binary labels: "Verification Possibility" and "Verification Importance," which are two criteria for check-worthiness. Factual claim was classified as a sentence with true verification possibility, of which the claim subject to actual fact check was viewed as a sentence with true verification importance.

Using our dataset and text classification technique, we trained a

classification model to detect check-worthy claims for Korean fact check. The final model was built by fine-tuning KoBERT, a deep learning language model which was pre-trained with the Korean corpus. Binary classification model was produced for each of the two labels of verification possibility and verification importance, and their performance was evaluated through accuracy, precision, recall, and F1-score. The verification possibility classification model showed high performance in all indicators, and the verification importance classification model also showed high performance in most indicators but the precision was relatively low.

This study first constructed a dataset of significant size to detect the Korean chech-worthy claims. The dataset may then be used as a data set for Korean natural language processing as well as a automating fact-check. In addition, our check-worthy classification model performed considerably high accuracy. This means that in the process of automating fact-check, the technique can be practically used to detect check-worthy claims.

Keywords : fact check, fact-checking, deep learning, language model, check-worthy claims
Student Number : 2017-20996